



UNIVERZITET U SARAJEVU
ELEKTROTEHNIČKI FAKULTET
ODSJEK ZA RAČUNARSTVO I INFORMATIKU

Kvantifikacija nesigurnosti u modelima umjetne inteligencije: okvir za prediktivno održavanje i analizu rizika

ZAVRŠNI RAD
- PRVI CIKLUS STUDIJA -

Student:
Muhamed Džafić

Mentor:
Doc. dr Kenan Šehić

Sarajevo, august 2026.

Sažetak

Ovaj rad se bavi kvantifikacijom nesigurnosti u modelima umjetne inteligencije za predikciju preostalog životnog vijeka industrijskih komponenti, s posebnim naglaskom na primjenu u prediktivnom održavanju. Deterministički modeli produciraju isključivo tačkastu procjenu bez mjere pouzdanosti, što ih čini nepouzdanim alatom za donošenje odluka u kritičnim sistemima poput avijacije i energetike. U radu su implementirane i sistemski uspoređene tri metode kvantifikacije nesigurnosti: Monte Carlo Dropout, Deep Ensemble i hibridna Bayesovska neuronska mreža, na zajedničkoj LSTM arhitekturi i NASA-inom CMAPSS skupu podataka. Evaluacija obuhvata metrike specifične za kvantifikaciju nesigurnosti: pokrivenost prediktivnih intervala, srednju širinu intervala, negativnu log-vjerodostojnost i srednju apsolutnu kalibracionu grešku. Rezultati pokazuju da sve tri metode postižu usporedivu tačnost predikcije kao deterministički baseline uz dodatnu vrijednost kvantificirane nesigurnosti, te da nijedna metoda ne dominira po svim metrikama istovremeno. Potvrđeno je da su tačnost predikcije i kalibracija nesigurnosti nezavisne dimenzije kvaliteta modela: metode se statistički ne razlikuju po tačnosti predikcije, ali se jasno razlikuju po kvaliteti kalibracije nesigurnosti. Za Monte Carlo Dropout i hibridnu Bayesovsku neuronsku mrežu, čija se nesigurnost generira kroz stohastičko uzorkovanje iz jedne distribucije, provedena je aproksimativna dekompozicija na epistemičku i aleatoričku komponentu, što predstavlja ključnu prednost za interpretabilnost modela u industrijskim primjenama.

Ključne riječi: kvantifikacija nesigurnosti, prediktivno održavanje, preostali životni vijek, Monte Carlo Dropout, Deep Ensemble, Bayesovska neuronska mreža, LSTM

Abstract

This thesis addresses uncertainty quantification in deep learning models for remaining useful life prediction of industrial components, with emphasis on application in predictive maintenance. Deterministic models produce only point estimates without any measure of reliability, making them inadequate for decision-making in safety-critical systems such as aviation and energy production. Three uncertainty quantification methods: Monte Carlo Dropout, Deep Ensemble, and a hybrid Bayesian neural network are implemented and systematically compared on a shared LSTM architecture using NASA's CMAPSS dataset. The evaluation includes metrics specific to uncertainty quantification: prediction interval coverage probability, mean interval width, negative log-likelihood, and mean absolute calibration error. Results show that all three methods achieve comparable prediction accuracy to the deterministic baseline while providing quantified uncertainty, and that no single method dominates across all metrics simultaneously. Prediction accuracy and uncertainty calibration are confirmed to be independent dimensions of model quality: the methods do not differ significantly in point-prediction accuracy, but differ meaningfully in calibration quality, and an approximate decomposition of uncertainty into epistemic and aleatoric components is performed for Monte Carlo Dropout and the hybrid Bayesian neural network, both of which generate uncertainty through stochastic sampling from a single distribution - a property that represents a key advantage for model interpretability in industrial applications.

Keywords: uncertainty quantification, predictive maintenance, remaining useful life, Monte Carlo Dropout, Deep Ensemble, Bayesian neural network, LSTM

Postavka zadatka završnog rada I ciklusa: **Kvantifikacija nesigurnosti u modelima umjetne inteligencije: okvir za prediktivno održavanje i analizu rizika**

Cilj ovog završnog rada je istražiti primjenu metoda kvantifikacije nesigurnosti u modelima dubokog učenja za predikciju preostalog životnog vijeka (engl. Remaining Useful Life, RUL) industrijskih komponenti, s posebnim naglaskom na primjenu u prediktivnom održavanju. Iako modeli umjetne inteligencije mogu dostići visoku tačnost predikcije, oni tipično produciraju isključivo tačkastu procjenu bez mjere pouzdanosti, što ih čini nedovoljno pouzdanim alatom za donošenje odluka u sigurnosno kritičnim sistemima poput avijacije i energetike. Rad će se fokusirati na implementaciju i sistemsku usporedbu više metoda kvantifikacije nesigurnosti, poput Monte Carlo Dropout-a, Deep Ensemble pristupa i Bayesovskih neuronskih mreža, primijenjenih na zajedničkoj rekurentnoj arhitekturi i evaluiranih na standardnom skupu podataka. Do kraja ovog projekta očekuje se da će student imati temeljno razumijevanje izvora nesigurnosti u prediktivnim modelima i njihove dekompozicije na epistemičku i aleatoričku komponentu. U radu će biti predstavljena evaluacija implementiranih metoda korištenjem skupa metrika specifičnih za kvantifikaciju nesigurnosti, uz analizu odnosa između tačnosti predikcije i kvalitete kalibracije nesigurnosti. Očekuje se da će rezultati doprinijeti razumijevanju praktičnih implikacija odabira metode kvantifikacije nesigurnosti u kontekstu prediktivnog održavanja industrijskih sistema.

Mentor: Doc. dr Kenan Šehić

Polazna literatura:

- Gal, Y., Ghahramani, Z., *Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning*, Proceedings of the 33rd International Conference on Machine Learning (ICML), Vol. 48, 2016, str. 1050–1059.
- Lakshminarayanan, B., Pritzel, A., Blundell, C., *Simple and Scalable Predictive Uncertainty Estimation Using Deep Ensembles*, Advances in Neural Information Processing Systems (NeurIPS), Vol. 30, 2017.
- Basora, L., Viens, A., Chao, M. A., Olive, X., *A Benchmark on Uncertainty Quantification for Deep Learning Prognostics*, arXiv preprint arXiv:2302.04730, 2023.
- Numerical Uncertainty Quantification for Extreme Wave Events, Šehić, Kenan, 2020.

Izjava o autentičnosti radova

Završni rad I ciklusa studija

Ime i prezime: Muhamed Džafić

Naslov rada: Kvantifikacija nesigurnosti u modelima umjetne inteligencije: okvir za prediktivno održavanje i analizu rizika

Vrsta rada: Završni rad Prvog ciklusa studija

Broj stranica: 45

Potvrđujem:

- da sam pročitao dokumente koji se odnose na plagijarizam, kako je to definirano Statutom Univerziteta u Sarajevu, Etičkim kodeksom Univerziteta u Sarajevu i pravilima studiranja koja se odnose na I i II ciklus studija, integrirani studijski program I i II ciklusa i III ciklus studija na Univerzitetu u Sarajevu, kao i uputama o plagijarizmu navedenim na web stranici Univerziteta u Sarajevu;
- da sam svjestan univerzitetskih disciplinskih pravila koja se tiču plagijarizma;
- da je rad koji predajem potpuno moj, samostalni rad, osim u dijelovima gdje je to naznačeno;
- da rad nije predat, u cjelini ili djelimično, za stjecanje zvanja na Univerzitetu u Sarajevu ili nekoj drugoj visokoškolskoj ustanovi;
- da sam jasno naznačio prisustvo citiranog ili parafraziranog materijala i da sam se referirao na sve izvore;
- da sam dosljedno naveo korištene i citirane izvore ili bibliografiju po nekom od preporučenih stilova citiranja, sa navođenjem potpune reference koja obuhvata potpuni bibliografski opis korištenog i citiranog izvora;
- da sam odgovarajuće naznačio svaku pomoć koju sam dobio pored pomoći mentora i akademskih tutora/ica.

Sarajevo, august 2026.

Potpis:

Muhamed Džafić

Sadržaj

Popis slika	vi
Popis tabela	vii
1 Uvod	1
1.1 Opis problema	2
1.2 Motivacija	2
1.3 Fokus i hipoteza	3
1.4 Metodologija	4
1.5 Očekivani rezultati	4
1.6 Pregled poglavlja	5
2 Pregled literature	6
2.1 Prediktivno održavanje metodama umjetne inteligencije	6
2.2 Metode kvantifikacija nesigurnosti	6
2.3 Postojeći pristupi UQ-u u predikciji preostalog životnog vijeka	7
3 Teorijska osnova	9
3.1 Preostali životni vijek (RUL)	9
3.2 LSTM arhitektura	10
3.3 Vrste nesigurnosti	10
3.3.1 Aleatorička nesigurnost	11
3.3.2 Epistemička nesigurnost	11
3.4 Metrike za evaluaciju nesigurnosti	12
3.4.1 RMSE i MAE	12
3.4.2 Pokrivenost prediktivnih intervala	12
3.4.3 Srednja širina intervala	13
3.4.4 Negativna log-vjerodostojnost	13
3.4.5 Srednja apsolutna kalibraciona greška	13
4 Metode kvantifikacije nesigurnosti	15
4.1 Monte Carlo Dropout	15
4.2 Deep Ensemble	17
4.3 Hibridna Bayesovska neuronska mreža	18
5 Skup podataka i pretprocesiranje	21
5.1 CMAPSS skup podataka	21
5.2 Eksplorativna analiza podataka	22
5.2.1 Distribucija životnog vijeka motora	22

5.2.2	Distribucija RUL labele	23
5.2.3	Identifikacija konstantnih senzora	23
5.2.4	Korelacijska analiza	24
5.3	Odabir relevantnih senzora	25
5.4	Konstrukcija RUL labele	25
5.5	Normalizacija i kreiranje sekvenci	26
6	Eksperimentalna evaluacija	29
6.1	Eksperimentalna postavka	29
6.2	Referentno pokretanje za eksperimentalnu evaluaciju	30
6.3	Eksperimentalni rezultati	32
6.3.1	Deterministički baseline model	32
6.3.2	Monte Carlo Dropout	33
6.3.3	Deep Ensemble	34
6.3.4	Hibridna Bayesovska neuronska mreža	34
6.4	Usporedne analize i diskusija	36
6.4.1	Dekompozicija nesigurnosti	36
6.4.2	Kalibracija prediktivnih intervala	37
6.4.3	Teorijska garancija pokrivenosti	38
6.4.4	Sinteza rezultata	39
7	Zaključak	41
7.1	Prijedlozi za budući rad	42
	Literatura	44
	Prilog A: Izvorni kod implementacije	46

Popis slika

1.1	Okvir prediktivnog održavanja s kvantifikacijom nesigurnosti: od senzorskih podataka do odluke o servisnoj intervenciji.	1
4.1	Usporedni prikaz arhitektura triju implementiranih metoda kvantifikacije nesigurnosti: MC Dropout, Deep Ensemble i Hibridni BNN.	17
5.1	Distribucija životnog vijeka za 100 motora u trening skupu CMAPSS FD001. .	22
5.2	Usporedba distribucije RUL labela bez ograničenja (lijevo) i s ograničenjem na 125 ciklusa (desno). Clipping rezultira ujednačenijom distribucijom i fokusira model na kritičnu fazu degradacije.	23
5.3	Standardna devijacija senzorskih mjerenja u trening skupu. Senzori čija je standardna devijacija ispod praga od 0.01 identificirani su kao konstantni i eliminiraju se iz skupa atributa.	23
5.4	Pearsonova korelacija senzora s RUL labelom nakon uklanjanja konstantnih senzora.	24
5.5	Vremenske serije triju najinformativnijih senzora za pet nasumično odabranih motora. Svaka linija odgovara jednom motoru. Razlike u nagibu i dužini trajektorija odražavaju inherentnu varijabilnost procesa degradacije.	24
6.1	Scatter plot predikcija determinističkog baseline modela nasuprot stvarnih RUL vrijednosti. Boja svake tačke kodira apsolutnu grešku predikcije: zeleno označava malu grešku, a crveno veliku. Dijagonala predstavlja idealnu predikciju. .	32
6.2	MC Dropout predikcije RUL-a s 95% intervalima nesigurnosti za sve motore u testnom skupu, sortirani po stvarnom RUL-u. Plava linija predstavlja predviđenu srednju vrijednost, a osjenčano područje interval $\hat{\mu} \pm 2\hat{\sigma}$	33
6.3	Deep Ensemble predikcije RUL-a s 95% intervalima nesigurnosti. Zelena linija predstavlja predviđenu srednju vrijednost, a osjenčano područje interval $\hat{\mu} \pm 2\hat{\sigma}$. .	34
6.4	Hibridni BNN predikcije RUL-a s 95% intervalima nesigurnosti. Crvena linija predstavlja predviđenu srednju vrijednost, a osjenčano područje interval $\hat{\mu} \pm 2\hat{\sigma}$. .	35
6.5	Krivulja konvergencije hibridnog BNN modela.	35
6.6	Aproksimativna dekompozicija nesigurnosti na aleatoričku i epistemičku komponentu za MC Dropout (lijevo) i hibridni BNN (desno). Motori su sortirani po stvarnom RUL-u.	36
6.7	Dijagram pouzdanosti za sve tri UQ metode. Isprekidana dijagonala predstavlja idealnu kalibraciju. Krivulje iznad dijagonale ukazuju na precjenjivanje nesigurnosti, a ispod na potcjenjivanje.	37

Popis tabela


4.1	Osjetljivost zajedničke LSTM arhitekture (dropout slojevi korišteni u MC Dropout i Deep Ensemble metodama) na dropout stopu p	16
4.2	Osjetljivost hibridnog BNN modela na dropout stopu p u determinističkim LSTM slojevima.	20
5.1	Karakteristike CMAPSS FD001 podskupa	21
5.2	Osjetljivost RMSE-a na dužinu ulaznog prozora W , uz udio test motora s dovoljno ciklusa za svaku vrijednost.	27
6.1	Osjetljivost RMSE-a na broj epoha treninga, bez <i>EarlyStopping</i> mehanizma. . .	30
6.2	Stabilnost modela kroz 10 nezavisnih pokretanja.	30
6.3	Odstupanje <i>coverage</i> -a svakog pokretanja od prosjeka kroz 10 nezavisnih pokretanja.	31
6.4	Usporedba originalnih i conformal prediction intervala za sve tri UQ metode (izračunato na 77 motora testnog skupa nakon izdvajanja kalibracionog skupa). .	39
6.5	Bootstrap 95% intervali pouzdanosti za RMSE.	39

1. Uvod

U posljednjih nekoliko decenija, industrijski sistemi visokog potiska postali su izuzetno složeni i skupi, a njihovo neplansko zaustavljanje može rezultirati ogromnim finansijskim gubicima, pa čak i ugrožavanjem ljudskih života. Mlazni motori, turbine i kompresori koji pokreću modernu industriju generiraju kontinuirane tokove senzorskih podataka tokom cijelog svog operativnog vijeka. Upravljanje ovim sistemima oduvijek je predstavljalo izazov: intervenisati pre-rano znači nepotrebno zaustavljati funkcionalne sisteme, a intervenisati prekasno znači riskirati katastrofalni kvar. Prediktivno održavanje nastoji riješiti ovaj problem korištenjem podataka za donošenje informiranih odluka o servisiranju, a njegova ključna komponenta je pouzdana procjena preostalog životnog vijeka (engl. *Remaining Useful Life*, RUL) komponenti, tj. broja operativnih ciklusa koji preostaju do kvara [1].

Sa brzim razvojem tehnika umjetne inteligencije, modeli zasnovani na neuronskim mrežama pokazali su izuzetnu sposobnost učenja kompleksnih degradacijskih obrazaca direktno iz senzorskih podataka, postižući rezultate koji značajno nadmašuju tradicionalne fizikalne i statističke modele [2]. Međutim, ovaj napredak u tačnosti predikcije prati jedna kritična slabost koja se u literaturi često zanemaruje: gotovo svi ovi modeli produciraju isključivo deterministički izlaz, jednu skalarnu vrijednost bez ikakve mjere pouzdanosti. U kontekstu kritičnih industrijskih primjena, ova slabost nije marginalna, već fundamentalna. Inženjer koji dobije predikciju da će motor otkazati za 47 ciklusa nema osnovu za procjenu koliko se može osloniti na tu informaciju. Je li model siguran u tu procjenu, ili samo nagađa na osnovu obrasca koji nikad nije vidio, primjenjujući ga na degradacijski profil izvan svog treninga? Bez odgovora na ovo pitanje, donošenje odgovornih odluka o održavanju nije moguće.

Ovaj rad bavi se upravo tom prazninom: kvantifikacijom nesigurnosti (engl. *Uncertainty Quantification*, UQ) u modelima umjetne inteligencije za predikciju RUL-a, s ciljem izgradnje okvira koji uz predikciju daje i mjeru pouzdanosti te predikcije. Slika 1.1 prikazuje cjelokupni tok prediktivnog održavanja s kvantifikacijom nesigurnosti koji se razvija u ovom radu.



Slika 1.1: Okvir prediktivnog održavanja s kvantifikacijom nesigurnosti: od senzorskih podataka do odluke o servisnoj intervenciji.

1.1 Opis problema

Deterministički pristup predikciji RUL-a u osnovi počiva na pretpostavci da model savršeno opisuje stvarni fizički proces degradacije. U praksi, ova pretpostavka gotovo nikada nije ispunjena. Proces degradacije mlaznih motora po svojoj prirodi je nasumičan: šum senzora uvodi nasumične fluktuacije u mjerenja, varijabilnost u materijalima i geometriji komponenti znači da nominalno identični motori imaju različite životne vijekove, a razlike u operativnim profilima dodatno povećavaju tu varijabilnost [3]. Čak i kada bi model savršeno naučio prosječni degradacijski obrazac, nasumičnost svojstvena procesu čini da će predikcija za bilo koji konkretni motor uvijek sadržavati određenu grešku.

Pored ove suštinske nesigurnosti koja potječe iz samih podataka, postoji i nesigurnost koja potječe iz ograničenja modela. Ako model nije vidio dovoljan broj primjera određenog tipa degradacijskog profila tokom treninga, njegove predikcije za motore s takvim profilima bit će nepouzdanе, čak i ako numerički izgledaju uvjerljivo. Standardne metrike evaluacije poput korigirane srednje kvadratne greške (RMSE) i srednje apsolutne greške (MAE) mjere samo tačnost tačkaste predikcije i ne daju nikakvu informaciju o ovim izvorima nepouzdanosti [4].

Posljedica ovog pristupa je da modeli s identičnim RMSE vrijednostima mogu imati dramatično različite profile pouzdanosti: jedan može biti konzistentno pouzdan kroz cijeli raspon ulaznih uvjeta, dok drugi može biti pouzdan samo za motore slične onima viđenim tokom treninga, a duboko nepouzdan za sve ostale. Bez mehanizma za kvantifikaciju nesigurnosti, ova razlika je nevidljiva korisniku modela.

1.2 Motivacija

Kritični industrijski sistemi, poput avionskih motora, nuklearnih elektrana i naftnih platformi, dijele jednu zajedničku karakteristiku: cijena greške je izuzetno visoka, a ponekad i neprihvatljiva. Neočekivani kvar motora u letu može imati katastrofalne posljedice po sigurnost putnika i posade. Prerani servis koji se mogao odgoditi za stotine operativnih sati generira ogromne direktne troškove zamjene dijelova i indirektnе troškove zastoja aviona. U ovakvim domenima, sposobnost modela da komunicira svoju pouzdanost jednako je važna kao i sama tačnost predikcije [1].

Ključna motivacija za ovaj rad leži u distinkciji između dvije fundamentalno različite vrste nesigurnosti koje se javljaju u probabilističkim modelima [5]. *Aleatorička nesigurnost* odražava suštinsku nasumičnost prisutnu u samim podacima koja ne može biti eliminirana bez obzira na količinu dostupnih podataka ili složenost modela. Ona je ireducibilna i svojstvena samom fizičkom procesu koji se modelira. U kontekstu degradacije mlaznih motora, aleatorička nesigurnost javlja se iz šuma senzora, varijabilnosti u materijalima i nasumičnosti samog procesa trošenja. *Epistemička nesigurnost*, s druge strane, odražava nedovoljno znanje modela i može se smanjiti prikupljanjem više podataka ili poboljšanjem arhitekture [6]. Ona je visoka kada model naiđe na ulazne podatke koji su značajno različiti od onih viđenih tokom treninga.

Ova distinkcija ima direktne praktične implikacije za donošenje odluka [7]. Kada model indicira visoku epistemičku nesigurnost za određeni motor, to je signal da model nije vidio dovoljno sličnih slučajeva i da treba prikupiti dodatne podatke ili razmotriti ponovni trening modela. Kada model indicira visoku aleatoričku nesigurnost, to je signal da je sam motor po svojoj prirodi nepredvidiv i da je konzervativniji pristup planiranju servisnih intervencija neophodan. Deterministički model ne može praviti ovu distinkciju, a time ni pružiti informaciju koja je ključna za odgovorno upravljanje industrijskim sistemima.

Unatoč rastućoj akademskoj pažnji posvećenoj UQ metodama u umjetnoj inteligenciji, sistemska usporedba ovih metoda na problemu RUL predikcije ostaje relativno neistražena [8]. Većina dostupnih radova fokusira se na jednu metodu bez sistemske usporedbe alternativa, evaluira nesigurnost isključivo kroz metriku pokrivenosti intervala bez sagledavanja kalibracije, ili ne provodi eksplicitnu dekompoziciju nesigurnosti na epistemičku i aleatoričku komponentu. Ovaj rad nastoji popuniti tu prazninu kroz strukturiranu implementaciju i usporedbu triju ustaljenih UQ metoda.

1.3 Fokus i hipoteza

Primarni fokus ovog rada je implementacija i sistemska usporedba triju ustaljenih metoda kvantifikacije nesigurnosti na problemu predikcije RUL-a, primijenjenih na zajedničkoj LSTM baznoj arhitekturi i evaluiranih na podskupu FD001 CMAPSS skupa podataka [3].

Prva metoda, Monte Carlo Dropout [9], zasniva se na teorijskom uvidu da aktiviranje dropout slojeva i tokom inferencije odgovara aproksimativnom Bayesovskom zaključivanju. Provedbom višestrukih stohastičkih prolaza kroz mrežu za isti ulaz dobiva se distribucija predikcija čija varijansa služi kao mjera nesigurnosti. Ključna prednost ove metode je minimalna računska cijena: ne zahtijeva izmjenu arhitekture niti postupka treninga.

Druga metoda, Deep Ensemble [10], zasniva se na treniranju više nezavisnih instanci iste arhitekture s različitim inicijalizacijama parametara. Raznolikost predikcija između članova ansambla tumači se primarno kao mjera epistemičke nesigurnosti, budući da nastaje zbog različitih hipoteza koje modeli usvajaju nad istim podacima. Ova metoda se u literaturi često smatra zlatnim standardom za UQ, no po cijeni višestruko povećane računske zahtjevnosti.

Treća metoda, hibridna Bayesovska neuronska mreža [11], direktno modelira distribuciju nad parametrima izlaznih slojeva mreže putem varijacione inferencije, dok rekurentni slojevi ostaju deterministički. Ovakav hibridni karakter predstavlja svjesni kompromis između teorijske rigoroznosti punog BNN-a i praktičnih računskih ograničenja.

Evaluacija se ne ograničava na standardne metrike tačnosti predikcije (RMSE i MAE), već obuhvata skup metrika specifičnih za kvantifikaciju nesigurnosti: pokrivenost prediktivnih intervala (CP), srednju širinu intervala (MIW), negativnu log-vjerodostojnost (NLL) i srednju apsolutnu kalibracionu grešku (MACE). Ovim skupom metrika moguće je procijeniti ne samo koliko je tačna predikcija srednje vrijednosti, nego i koliko je vjerodostojna procijenjena nesigurnost.

Hipoteza ovog rada je da metode kvantifikacije nesigurnosti zasnovane na različitim probabilističkim principima produciraju kvalitativno različite profile nesigurnosti i različit kvalitet kalibracije, iako postižu statistički usporedivu tačnost tačkaste predikcije. Tačnost i kalibracija nesigurnosti time se pokazuju kao dvije nezavisne dimenzije kvaliteta modela, razlika koju standardne RMSE/MAE metrike same po sebi ne mogu otkriti. Konkretno, aproksimativno Bayesovsko zaključivanje koje koriste MC Dropout i hibridna BNN, te funkcionalna raznolikost modela na kojoj počiva Deep Ensemble, vode do različitih karakteristika procjene nesigurnosti. Nadalje, pretpostavlja se da metode čija se nesigurnost generira kroz stohastičko uzorkovanje, MC Dropout i hibridna BNN, omogućavaju aproksimativnu dekompoziciju ukupne nesigurnosti na epistemičku i aleatoričku komponentu, za razliku od Deep Ensemble-a, čija nesigurnost proizlazi iz neusaglašenosti nezavisnih modela. Ova dekompozicija predstavlja informaciju ključnu za odgovorno donošenje odluka u industrijskim sistemima.

1.4 Metodologija

Kako bi se testirala iznesena hipoteza, rad slijedi strukturirani eksperimentalni pristup koji se može podijeliti u četiri faze.

U prvoj fazi, provodi se pretprocesiranje CMAPSS FD001 skupa podataka, koji modelira degradaciju modula kompresora visokog pritiska turbofan motora u jednom operativnom uvjetu i s jednim tipom kvara [3]. Pretprocesiranje uključuje eksplorativnu analizu podataka kojom su identificirani i eliminisani konstantni senzori, konstrukciju RUL labela s gornjom granicom od 125 ciklusa prema ustaljenoj praksi u literaturi [12, 13], min-max normalizaciju i kreiranje vremenskih sekvenci dužine 40 ciklusa kliznim prozorom.

U drugoj fazi, kao referentna tačka treniran je deterministički baseline LSTM model bez UQ komponente, koji se sastoji od dva rekurentna sloja s 64 i 32 jedinice te dva gusta sloja. Ova arhitektura služi kao zajednička osnova za sve tri UQ metode, čime se izolira doprinos UQ mehanizma od arhitekturnih razlika.

U trećoj fazi, implementirane su sve tri UQ metode na ovoj zajedničkoj arhitekturi. Tokom inferencije, za svaki testni uzorak provodi se 100 stohastičkih prolaza za MC Dropout i hibridnu BNN, dok Deep Ensemble agregira predikcije pet nezavisno treniranih modela, pri čemu svaki model daje 20 stohastičkih prolaza. Na taj način, ukupan broj uzoraka po ulazu ostaje jednak za sve metode, što osigurava direktnu usporedivost procijenjenih intervala nesigurnosti.

U četvrtoj fazi, sve metode evaluiraju se na istom testnom skupu korištenjem punog skupa metrika: RMSE i MAE za tačnost tačkaste predikcije, te CP, MIW, NLL i MACE za kvalitet procjene nesigurnosti.

1.5 Očekivani rezultati

Rezultati ovog rada trebali bi pokazati da probabilistički modeli mogu postići usporedivu tačnost predikcije kao deterministički baseline model, uz dodatnu vrijednost u vidu kvantificirane nesigurnosti. Očekuje se da će Deep Ensemble pokazati konzistentno dobru kalibraciju zahvaljujući funkcionalnoj raznolikosti modela koji čine ansambl [10], dok će MC Dropout biti računski najefikasniji pristup zbog odsustva potrebe za višestrukim nezavisnim treninzima [9]. Za MC Dropout i hibridnu BNN, čija se nesigurnost generira kroz stohastičko uzorkovanje, očekuje se da će omogućiti aproksimativnu dekompoziciju ukupne nesigurnosti na epistemičku i aleatoričku komponentu [14], za razliku od Deep Ensemble-a čija varijansa odražava neusaglašenost nezavisnih modela. Ova dekompozicija predstavlja korisnu heuristiku u kontekstu interpretabilnosti modela za potrebe prediktivnog održavanja.

Doprinos rada je trostruk. Prvo, evaluacija se temelji na skupu UQ-specifičnih metrika koji omogućava sveobuhvatnu usporedbu ne samo tačnosti nego i pouzdanosti procjene nesigurnosti, što predstavlja metodološki korak naprijed u odnosu na radove koji se ograničavaju isključivo na RMSE i MAE. Drugo, eksplicitna diskusija o dekompoziciji nesigurnosti za metode zasnovane na stohastičkom uzorkovanju (MC Dropout i hibridna BNN), uz jasno navođenje ograničenja svakog pristupa i razloga zbog kojih dekompozicija nije konceptualno primjenjiva na Deep Ensemble, doprinosi razumijevanju praktičnih implikacija odabira UQ metode u industrijskim sistemima. Treće, namjerno ograničavanje na FD001 podskup i standardizirana arhitektura osiguravaju reproducibilnost i direktnu usporedivost s relevantnim referentnim radovima [2, 8, 13].

1.6 Pregled poglavlja

Poglavlje 2 daje sistematski pregled relevantne literature. Obuhvaćeni su radovi o prediktivnom održavanju pomoću umjetne inteligencije i primjeni LSTM arhitektura za predikciju RUL-a, pregled poznatih metoda kvantifikacije nesigurnosti, te specifične primjene UQ-a na problem prognostike, s naglaskom na pozicioniranje ovog rada u odnosu na postojeće pristupe i identifikaciju praznina koje ovaj rad nastoji popuniti.

Poglavlje 3 postavlja teorijsku osnovu rada. Obuhvaćena je formalna definicija RUL-a i *piecewise linear* modela degradacije, opis LSTM arhitekture i njen odnos prema problemu modeliranja vremenskih serija senzorskih podataka, klasifikacija i matematička formalizacija aleatoričke i epistemičke nesigurnosti, te detaljan opis skupa metrika korištenih za evaluaciju probabilističkih modela.

Poglavlje 4 detaljno opisuje tri implementirane metode kvantifikacije nesigurnosti. Za svaku metodu dato je teorijsko utemeljenje, opis arhitekturnih modifikacija u odnosu na deterministički baseline model, te komentar o mogućnosti dekompozicije nesigurnosti na epistemičku i aleatoričku komponentu.

Poglavlje 5 opisuje CMAPSS skup podataka i sve korake pretprocesiranja. Uključuje rezultate eksplorativne analize podataka, koja je motivirala odabir relevantnih senzora, konstrukciju RUL labele i parametre normalizacije i kreiranja sekvenci.

Poglavlje 6 prezentira eksperimentalne rezultate. Pored rezultata svakog od četiri modela s punim skupom metrika, poglavlje sadrži usporednu analizu koja pokazuje da se metode statistički ne razlikuju po tačnosti predikcije, ali se jasno razlikuju po kvaliteti kalibracije nesigurnosti, te diskutira praktične implikacije ovog nalaza za primjenu u prediktivnom održavanju.

Poglavlje 7 donosi zaključke rada, sažetak ključnih nalaza, diskusiju o ograničenjima trenutnog pristupa i konkretne prijedloge za buduća istraživanja.

2. Pregled literature

2.1 Prediktivno održavanje metodama umjetne inteligencije

Prediktivno održavanje predstavlja strategiju upravljanja industrijskim sistemima u kojoj se odluke o servisiranju donose na osnovu stvarnog stanja opreme, a ne unaprijed određenih vremenskih intervala. Središnji element ove strategije je pouzdana procjena preostalog životnog vijeka (engl. *Remaining Useful Life* – RUL) komponenti [1]. Sa razvojem umjetne inteligencije, podatkovno vođeni pristupi predikciji RUL-a postali su dominantna istraživačka paradigma, budući da omogućuju automatsko učenje reprezentacija iz sirovih senzorskih podataka bez potrebe za ručnim inženjeringom značajki.

Rekurentne neuronske mreže, a posebno arhitektura dugog kratkoročnog pamćenja (engl. *Long Short-Term Memory* – LSTM), pokazale su se izuzetno pogodnim za modeliranje vremenskih serija senzorskih podataka [15]. Zheng et al. [2] bili su među prvima koji su demonstrirali primjenu LSTM mreže za direktnu predikciju RUL-a na CMAPSS skupu podataka, postavljajući metodološki okvir koji su kasniji radovi naširoko preuzeli. Zhang et al. [12] proširili su ovaj pristup pokazujući da LSTM arhitektura s odgovarajućim podešavanjem hiperparametara može nadmašiti klasičnije metode zasnovane na konvolucijskim neuronskim mrežama ili potpuno povezanim slojevima na istom zadatku.

Referentni skup podataka koji se koristio u gotovo svim ovim istraživanjima je NASA-in CMAPSS (engl. *Commercial Modular Aero-Propulsion System Simulation*) skup podataka, kojega su opisali Saxena et al. [3]. CMAPSS simulira degradaciju mlaznih motora visokog potiska kroz senzorska mjerenja 21 varijable prikupljenih tokom ciklusa od normalnog rada do kvara. Skup sadrži četiri pododskupa (FD001–FD004) koji se razlikuju po broju operativnih uvjeta i modova kvara, čime se omogućuje testiranje algoritama u scenarijima različite složenosti. Zahvaljujući javnoj dostupnosti, jasno definiranoj metričkoj osnovi i reprezentativnosti za realne industrijske scenarije, CMAPSS je postao *de facto* standard za usporedbu metoda predikcije RUL-a u akademskoj zajednici [8].

Unatoč znatnom napretku u tačnosti predikcije, dominantna većina radova iz ove oblasti ograničava se na determinističke modele koji produciraju samo tačkaste procjene RUL-a, bez kvantifikacije nesigurnosti vezane uz te procjene [13]. Ovakav pristup zadovoljava u istraživačkim postavkama, no za primjenu u realnim industrijskim sistemima, posebno onima s visokim zahtjevima pouzdanosti poput avijacije i energetike, tačkasta predikcija bez mjere pouzdanosti nije dovoljna za odgovorno donošenje odluka.

2.2 Metode kvantifikacija nesigurnosti

Kvantifikacija nesigurnosti (engl. *Uncertainty Quantification* – UQ) u kontekstu modela umjetne inteligencije proučava kako modelirati i izraziti pouzdanost predikcija neuronskih mreža. Fundamentalni okvir za razumijevanje izvora nesigurnosti uveli su Der Kiureghian i Ditlevsen [5],

razlikujući dvije fundamentalno različite komponente: aleatoričku nesigurnost, koja potiče iz suštinske nasumičnosti sistema i ne može se eliminirati dodatnim podacima, te epistemičku nesigurnost, koja odražava nedovoljno znanje modela i može se reducirati boljim podacima ili modelom. Kendall i Gal [6] prenijeli su ovu distinkciju u domenu Bayesovskog dubokog učenja, postavljajući teorijske temelje za dekompoziciju ukupne nesigurnosti u ove dvije komponente.

Bayesovske neuronske mreže (BNN) predstavljaju teorijski najrigorozniji pristup UQ-u u umjetnoj inteligenciji. Ideja datira još od MacKaya [16], koji je predložio Bayesovski okvir za neuronske mreže trenirane algoritmom bekpropagacije, u kojemu su težine mreže slučajne varijable s apriornom i posteriornom distribucijom. Budući da je egzaktno Bayesovsko zaključivanje za neuronske mreže računski neizvedivo, razvijene su metode aproksimativnog zaključivanja. Blundell et al. [11] predložili su algoritam *Bayes by Backprop*, koji koristi varijaciono zaključivanje za efikasnu aproksimaciju posteriorne distribucije težina. Graves [17] je ranije razvio praktičnu varijacionu inferenciju za neuronske mreže. Jospin et al. [14] daju sveobuhvatan pregled Bayesovskih neuronskih mreža s praktičnim naglaskom na implementaciju.

Monte Carlo Dropout (MCD) metodu uveli su Gal i Ghahramani [9], pokazavši da aktiviranje dropout slojeva i tokom faze inferencije, a ne samo tokom treniranja, odgovara aproksimativnom Bayesovskom zaključivanju. Ovaj pristup je praktično atraktivan jer ne zahtijeva modificiranje arhitekture niti treniranja u odnosu na standardne mreže s dropoutom [18]. Provedbom T stohastičkih propagacija unaprijed za isti ulaz dobiva se skup predikcija čija se varijansa može interpretirati kao mjera nesigurnosti modela.

Duboki ensemblovi (DE) predstavljaju alternativni pristup koji su predložili Lakshminarayanan et al. [10]. Metoda se zasniva na treniranju M neovisnih neuronskih mreža s različitim inicijalizacijama težina i agregiranju njihovih predikcija. Različitost modela u ansamblu nastaje kao posljedica nekonveksnosti prostora optimizacije i slučajnih inicijalizacija, te se primarno tumači kao mjera epistemičke nesigurnosti. Dietterich [19] je još ranije pokazao da ansambl metode reduciraju varijansu predikcije i poboljšavaju generalizaciju u odnosu na pojedinačne modele. Duboki ensemblovi se u praksi često smatraju zlatnim standardom za UQ jer su jednostavni za implementaciju i dobro kalibrirani [10].

2.3 Postojeći pristupi UQ-u u predikciji preostalog životnog vijeka

Primjena UQ metoda specifično na problem predikcije RUL-a ostala je relativno neistražena sve do nedavno. Većina radova koja se bavi ovom problematikom fokusira se na jednu od metoda bez sistemske usporedbe alternativa, ili evaluira nesigurnost isključivo kroz metriku pokrivenosti intervala bez sagledavanja kalibracije.

Caceres et al. [20] predložili su probabilistički Bayesovski rekurentni model koji istovremeno uzima u obzir epistemičku i aleatoričku nesigurnost za predikciju RUL-a, validirajući pristup na CMAPSS skupu podataka. Srinivasan et al. [13] koristili su ansambl LSTM mreža s probabilističkim izlazima za razdvajanje ove dvije komponente nesigurnosti, pokazujući da epistemička nesigurnost pouzdano indicira distribucijsku neusklađenost između skupova podataka za trening i testiranje. Benker et al. [21] uspoređivali su Hamiltonov Monte Carlo i *Bayes by Backprop* na CMAPSS-u, no bez sistemske evaluacije kalibracije.

Hüllemeier i Waegeman [7] dali su sveobuhvatan pregled koncepta aleatoričke i epistemičke nesigurnosti u mašinskom učenju s teorijskim i praktičnim aspektima. Gneiting i Raftery [4] postavili su teorijske temelje za *proper scoring rules* – metriku koja istovremeno vrednuje tačnost predikcije i kvalitetu procjene nesigurnosti, te NLL kao primjer takve metrike. Kuleshov

et al. [22] razvili su metodu kalibracije regresionih modela koja se može primijeniti na bilo koji probabilistički prediktor.

Najsveobuhvatniji sistemski pregled UQ metoda u prognostici predstavlja rad Basore et al. [8], koji na N-CMAPSS skupu podataka uspoređuje HNN, varijacione BNN metode (LRT, Flipout, Radial BNN), MCD i DE uz standardiziranu Inception arhitekturu. Njihovi rezultati pokazuju da nijedna metoda jasno ne dominira u svim scenarijima: DE i MCD su konzervativniji u procjeni nesigurnosti i postižu bolje NLL rezultate, dok BNN metode pate od pretjerane pouzdanosti u pojedinim skupovima. Zanimljivo, HNN kao najjednostavnija metoda postiže kompetitivne rezultate u kalibraciji uz znatno manje računske zahtjeve.

Ovaj rad doprinosi postojećoj literaturi na nekoliko načina. Prvo, dok se većina studija oslanja isključivo na metrike tačnosti poput RMSE i MAE, ovdje se evaluacija temelji na skupu metrika specifičnih za UQ: pokrivenost intervala, prosječna širina intervala, NLL i MACE, što omogućuje obuhvatniju procjenu kvalitete nesigurnosti. Drugo, eksplicitno se implementira i diskutira dekompozicija ukupne nesigurnosti na epistemičku i aleatoričku komponentu za MC Dropout i hibridnu BNN, uz jasno navođenje ograničenja svakog pristupa. Treće, za razliku od radova koji se oslanjaju na N-CMAPSS ili kombinaciju više podskupova, ovaj rad se namjerno fokusira na FD001 pododskup CMAPSS-a kako bi se omogućila izolirana i reproducibilna analiza pod jednim operativnim uvjetom i jednim modom kvara, što je metodološki konzistentno s praksom u relevantnim referentnim radovima [2, 13].

3. Teorijska osnova

3.1 Preostali životni vijek (RUL)

Preostali životni vijek (eng. *Remaining Useful Life*, RUL) definira se kao broj preostalih operativnih ciklusa, sati rada ili nekog drugog mjerila vremena do kojeg se očekuje da komponenta ili sistem može funkcionirati unutar prihvatljivih performansnih granica [3]. Formalno, za sistem koji se u trenutku t nalazi u određenom stanju degradacije, RUL se može zapisati kao:

$$\text{RUL}(t) = T_f - t \quad (3.1)$$

gdje je T_f trenutak kada sistem dostiže unaprijed definiranu granicu kvara (eng. *failure threshold*), a t je tekući trenutak posmatranja. Procjena RUL-a spada u domen prognostike, koju Saxena et al. [3] definiraju isključivo kao estimaciju preostalog korisnog vijeka komponente, izraženu u jedinicama vremena ili ciklusa.

Precizna procjena RUL-a od ključnog je značaja za prediktivno održavanje (eng. *predictive maintenance*) u industrijskim sistemima. Za razliku od reaktivnog održavanja koje nastupa nakon nastanka kvara i preventivnog održavanja koje se provodi prema unaprijed definiranom rasporedu bez uvida u stvarno stanje sistema, prediktivno održavanje koristi podatke dobijene iz senzora kako bi rasporedilo intervencije u optimalnom trenutku [1]. Na taj način moguće je izbjeći neplanirane zastoje u radu, produžiti operativni vijek opreme i smanjiti ukupne troškove održavanja, što je posebno važno u kritičnim domenima poput avijacije i energetike gdje su posljedice neočekivanog kvara visoke [3].

Kako bi se RUL mogao učiti iz podataka, potrebno je konstruirati odgovarajuću labelu za svaki uzorak u trening skupu. U CMAPSS setu podataka, koji je korišten u ovom radu, svaki motor u trening skupu prati se od nekog inicijalnog stanja do potpunog otkaza [3]. Za motor koji ukupno ima T ciklusa rada, RUL u ciklusu t iznosi:

$$\text{RUL}(t) = T - t \quad (3.2)$$

Međutim, direktna primjena ove formule rezultira velikim vrijednostima RUL-a na početku životnog vijeka motora, što je problematično jer su fizički procesi degradacije u ranoj fazi života sistema teško uočljivi u senzorskim podacima, motor se ponaša praktično identično zdravom sistemu. Iz tog razloga, u literaturi se široko primjenjuje tzv. *piecewise linear* model degradacije [12], koji uvodi gornju granicu (*cap*) na vrijednost RUL labela:

$$\text{RUL}_{\text{cap}}(t) = \min(\text{RUL}(t), C) \quad (3.3)$$

gdje je C odabrana konstantna vrijednost koja predstavlja maksimalni RUL koji model “vidi” tokom treninga. Pretpostavka iza ovog pristupa je da dok je motor daleko od kvara, sistem se ponaša kao zdrav bez jasnih znakova degradacije koji bi bili vidljivi iz senzorskih mjerenja, stoga nema smisla razlikovati RUL od, recimo, 200 ciklusa od RUL-a od 300 ciklusa. Tek kada

RUL padne ispod praga C , počinje linearna faza degradacije koja je modelima za učenje zaista vidljiva u podacima.

U kontekstu CMAPSS FD001 seta podataka, standardna vrijednost ovog praga iznosi $C = 125$ ciklusa, što je u skladu s praksom uspostavljenu u ranijim radovima koji su koristili isti skup podataka [12, 13]. Ova vrijednost pokazala se robusnom u velikom broju istraživanja i danas predstavlja *de facto* standard pri radu s CMAPSS skupom podataka, što olakšava usporedbu rezultata između različitih pristupa.

3.2 LSTM arhitektura

Podaci o degradaciji motora prirodno su organizirani kao vremenske serije, svaki motor generira sekvencu senzorskih očitavanja tokom svog operativnog vijeka, pri čemu trenutno stanje degradacije ovisi o prethodnim stanjima. Rekurentne neuronske mreže (eng. *Recurrent Neural Networks*, RNN) uvedene su s ciljem modeliranja ovakvih sekvencijalnih zavisnosti, međutim u praksi pate od problema nestajućeg gradijenta (eng. *vanishing gradient*) [15]. Tokom bekpropagacije kroz vrijeme, gradijenti se množe kroz veliki broj vremenskih koraka i eksponencijalno se smanjuju, zbog čega klasični RNN praktično ne može naučiti zavisnosti između udaljenih vremenskih koraka, što je upravo kritično za RUL predikciju, gdje rane faze degradacije mogu biti relevantne za procjenu preostalog vijeka stotine ciklusa kasnije [2].

Dugoročna kratkoročna memorija (eng. *Long Short-Term Memory*, LSTM), koju su uveli Hochreiter i Schmidhuber [15], rješava ovaj problem uvođenjem posebne memorijske ćelije $\mathbf{c}_t$ i mehanizma vrata koji kontroliraju tok informacija. Vrata zaborava (eng. *forget gate*) odlučuju koje informacije iz prethodnog stanja ćelije treba odbaciti, ulazna vrata (eng. *input gate*) određuju koje nove informacije treba pohraniti, a izlazna vrata (eng. *output gate*) kontroliraju koji dio stanja ćelije postaje izlaz mreže. Ažuriranje stanja ćelije odvija se aditivno:

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t \quad (3.4)$$

gdje $\odot$ označava *element-wise* množenje, $\mathbf{f}_t$ izlaz vrata zaborava, a $\mathbf{i}_t \odot \tilde{\mathbf{c}}_t$ novi sadržaj koji se upisuje u ćeliju. Upravo ova aditivna priroda ažuriranja omogućava gradijentu da teče kroz $\mathbf{c}_t$ bez multiplikativnog smanjivanja, čime se direktno adresira slabost klasičnog RNN-a [15].

Zahvaljujući ovim svojstvima, LSTM je postao standardni izbor za predikciju RUL-a u literaturi o prediktivnom održavanju [2, 13]. Sposobnost mreže da zadrži relevantne informacije iz ranih faza operativnog vijeka motora, dok istovremeno zaboravlja kratkotrajne fluktuacije, direktno odgovara prirodi problema degradacije koji se modelira u ovom radu.

3.3 Vrste nesigurnosti

U kontekstu primjene modela umjetne inteligencije za predikciju RUL-a, sama tačnost predikcije nije dovoljna za pouzdano donošenje odluka u industrijskim sistemima. Jednako važno je razumjeti *zašto* model griješi i *koliko* se može vjerovati određenoj predikciji. U tu svrhu, literatura razlikuje dvije fundamentalno različite vrste nesigurnosti koje se javljaju u probabilističkim modelima: aleatoričku i epistemičku nesigurnost [5, 6]. Razumijevanje ove distinkcije ključno je ne samo za interpretaciju izlaza modela, već i za donošenje praktičnih odluka o održavanju.

3.3.1 Aleatorička nesigurnost

Aleatorička nesigurnost predstavlja nasumičnost svojstvenu procesu koja je prisutna u samim podacima i ne može biti eliminirana bez obzira na količinu dostupnih podataka ili složenost modela [5]. Ova vrsta nesigurnosti je ireducibilna, ona je svojstvena procesu koji se modelira, a ne nedostatku znanja.

U kontekstu degradacije mlaznih motora, aleatorička nesigurnost javlja se iz više izvora. Šum senzora uvodi slučajna odstupanja u mjerenja koja ne odražavaju stvarne promjene u stanju motora. Varijabilnost u procesu proizvodnje znači da čak i nominalno identični motori imaju mikroskopske razlike u materijalnim svojstvima i geometriji komponenti. Različiti operativni profili: razlike u opterećenju, temperaturi okoline i uvjetima leta dodatno doprinose varijabilnosti između motora. Konačno, prirodna stohastičnost samog procesa degradacije, poput nasumične nukleacije pukotina ili varijabilnosti u brzini trošenja, znači da dva identična motora operirana u identičnim uvjetima neće imati identičan životni vijek [3, 13].

Matematički, aleatorička nesigurnost se modelira heteroscedastičnom distribucijom izlaza. Model predviđa ne samo srednju vrijednost RUL-a, već i varijabilnost oko te srednje vrijednosti koja je funkcija ulaznih podataka:

$$p(y | \mathbf{x}) = \mathcal{N}(\mu(\mathbf{x}), \sigma_{\text{al}}^2(\mathbf{x})) \quad (3.5)$$

gdje $\mu(\mathbf{x})$ predstavlja predviđeni RUL, a $\sigma_{\text{al}}^2(\mathbf{x})$ je aleatorička varijansa koja se mijenja ovisno o ulazu $\mathbf{x}$ [6]. Važno je naglasiti da prikupljanje više podataka o ovim motorima ne može smanjiti ovaj tip nesigurnosti, ona ostaje konstantna jer odražava stvarnu fizičku varijabilnost sistema [5].

3.3.2 Epistemička nesigurnost

Epistemička nesigurnost predstavlja nesigurnost koja proizlazi iz nedovoljnog znanja modela o problemu koji modelira [5]. Za razliku od aleatoričke, ova vrsta nesigurnosti je reducibilna, može se smanjiti prikupljanjem više podataka, poboljšanjem arhitekture modela ili boljim algoritmima učenja [6].

U praktičnom smislu, epistemička nesigurnost je visoka kada model naiđe na ulazne podatke koji su značajno različiti od onih viđenih tokom treninga, tzv. situacija izvan distribucije (eng. *out-of-distribution*, OOD). Na primjer, ako je model treniran isključivo na motorima koji pokazuju jedan obrazac degradacije, predikcija za motor s drugačijim obrascem trošenja bit će praćena visokom epistemičkom nesigurnošću. Ovo je posebno relevantno u avijacijskom kontekstu, gdje različiti operativni uvjeti i konfiguracije motora mogu rezultirati degradacijskim profilima koji nisu bili zastupljeni u trening skupu [8].

U okviru Bayesovskih neuronskih mreža, epistemička nesigurnost se modelira distribucijom nad parametrima modela ω umjesto fiksним vrijednostima:

$$p(y | \mathbf{x}, \mathcal{D}) = \int p(y | \mathbf{x}, \omega) p(\omega | \mathcal{D}) d\omega \quad (3.6)$$

gdje $p(\omega | \mathcal{D})$ predstavlja posterior distribuciju parametara modela nakon što je model vidio podatke $\mathcal{D}$ [6]. Širina ove distribucije direktno kodira epistemičku nesigurnost: uski posterior odgovara velikom povjerenju modela, dok široki posterior ukazuje na nesigurnost u parametrima.

3.4 Metrike za evaluaciju nesigurnosti

Standardne metrike tačnosti predikcije, poput srednje kvadratne greške i srednje apsolutne greške, mjere isključivo kvalitet tačkaste predikcije, tj. koliko je predviđena srednja vrijednost blizu stvarne vrijednosti RUL-a. Međutim, u kontekstu kvantifikacije nesigurnosti, model koji daje tačne predikcije ali pogrešno procjenjuje vlastitu nesigurnost jednako je nepouzdan kao i model s lošom tačnošću [4]. Probabilistički model koji je siguran u pogrešnu predikciju, tzv. *overconfident* model može biti opasniji od determinističkog modela u kritičnim industrijskim primjenama, jer navodi inženjere na pogrešne odluke s lažnim osjećajem pouzdanosti [8]. Iz tog razloga, evaluacija UQ modela zahtijeva skup metrika koji obuhvata dvije komplementarne dimenzije kvaliteta probabilističke predikcije: *kalibraciju* – koliko dobro predviđene vjerojatnosti odgovaraju stvarnim frekvencijama i *oštrinu* – koliko su prediktivni intervali uski, što odražava informativnost modela [22].

3.4.1 RMSE i MAE

Korijen srednje kvadratne greške (eng. *Root Mean Square Error*, RMSE) i srednja apsolutna greška (eng. *Mean Absolute Error*, MAE) predstavljaju standardne metrike tačnosti predikcije koje se koriste kao referentna tačka pri usporedbi modela:

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2} \quad (3.7)$$

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |\hat{y}_i - y_i| \quad (3.8)$$

gdje je $\hat{y}_i$ predviđena vrijednost RUL-a, y_i stvarna vrijednost, a N ukupan broj uzoraka. RMSE penalizira veće greške kvadratno, što ga čini osjetljivijim na ekstremne vrijednosti, dok MAE pruža robustiju mjeru prosječne greške [8]. Obje metrike operiraju isključivo na tačkastim predikcijama, tipično na predviđenoj srednjoj vrijednosti $\mu(\mathbf{x})$ i stoga ne pružaju nikakvu informaciju o kvalitetu procijenjene nesigurnosti. Dva modela s identičnim RMSE vrijednostima mogu imati drastično različitu kalibraciju prediktivnih intervala, što ih čini nedovoljnima kao jedine metrike evaluacije probabilističkih modela [4].

3.4.2 Pokrivenost prediktivnih intervala

Vjerovatnoća pokrivenosti (eng. *Coverage Probability*, CP), poznatija i kao PICP (eng. *Prediction Interval Coverage Probability*), mjeri koliki udio stvarnih vrijednosti pada unutar konstruiranog prediktivnog intervala na zadanoj razini pouzdanosti α [13]:

$$\text{CP}_\alpha = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[y_i \in [L_\alpha(\mathbf{x}_i), U_\alpha(\mathbf{x}_i)]] \quad (3.9)$$

gdje su $L_\alpha(\mathbf{x}_i)$ i $U_\alpha(\mathbf{x}_i)$ donja i gornja granica prediktivnog intervala pri razini pouzdanosti α , a $\mathbf{1}[\cdot]$ indikatorna funkcija. Za dobro kalibriran model, empirijska pokrivenost treba odgovarati nominalnoj razini pouzdanosti, tj. $\text{CP}_\alpha \approx \alpha$. Na primjer, pri $\alpha = 0.95$, oko 95% stvarnih vrijednosti trebalo bi pasti unutar prediktivnog intervala. Model s $\text{CP}_{0.95} \ll 0.95$ je *overconfident* – njegovi intervali su preuski i ne obuhvataju dovoljno stvarnih vrijednosti. Obrnuto, model s $\text{CP}_{0.95} \gg 0.95$ je *underconfident* – njegovi intervali su preširoki i stoga neinformativni [22].

CP je neophodan ali ne i dovoljan uvjet za kalibriranost: trivijalni model koji uvijek predviđa beskonačno širok interval postiže $CP = 1.0$, ali je potpuno neinformativan.

3.4.3 Srednja širina intervala

Srednja širina intervala (eng. *Mean Interval Width*, MIW), poznata i kao NMPIW (eng. *Normalized Mean Prediction Interval Width*) u normaliziranoj varijanti, mjeri prosječnu širinu prediktivnih intervala [13]:

$$MIW = \frac{1}{N} \sum_{i=1}^N [U_{\alpha}(\mathbf{x}_i) - L_{\alpha}(\mathbf{x}_i)] \quad (3.10)$$

MIW direktno kvantificira oštrinu probabilističke predikcije: uži interval znači da model daje preciznije i informativnije procjene nesigurnosti [4]. Ova metrika je smisljena jedino u kombinaciji s CP: uski interval koji ne postiže zadovoljavajuću pokrivenost je simptom *overconfidence*-a, dok širok interval koji postiže visoku pokrivenost ukazuje na *underconfidence*. Optimalan model minimizira MIW uz zadržavanje $CP_{\alpha} \approx \alpha$, što predstavlja fundamentalni kompromis između kalibracije i oštine u probabilističkoj predikciji [22].

3.4.4 Negativna log-vjerodostojnost

Negativna log-vjerodostojnost (eng. *Negative Log-Likelihood*, NLL) jedina je od razmatranih metrika koja simultano evaluira i tačnost predikcije i kvalitet procijenjene nesigurnosti u jednoj skalnoj vrijednosti, čime predstavlja tzv. *proper scoring rule* [4]. Za Gaussovsku pretpostavku o distribuciji predikcije, NLL se računa kao:

$$NLL = \frac{1}{N} \sum_{i=1}^N \left[\frac{1}{2} \log(2\pi\hat{\sigma}_i^2) + \frac{(y_i - \hat{\mu}_i)^2}{2\hat{\sigma}_i^2} \right] \quad (3.11)$$

gdje su $\hat{\mu}_i$ i $\hat{\sigma}_i^2$ predviđena srednja vrijednost i varijansa za i -ti uzorak. Iz strukture ove formule jasno se vidi mehanizam penalizacije: prvi član penalizira modele koji predviđaju veliku nesigurnost (široke distribucije), dok drugi član penalizira modele čija je predikcija daleko od stvarne vrijednosti, pri čemu ta penalizacija raste inverzno s procijenjenom nesigurnošću. Stoga, model koji je visoko siguran ($\hat{\sigma}_i^2 \ll 1$) a istovremeno griješi biva ekstremno penaliziran, što je upravo željeno ponašanje metrike u kontekstu sigurnosno kritičnih sistema [8]. Treba napomenuti da NLL pretpostavlja Gaussovsku distribuciju predikcije, što može biti restriktivno u slučajevima kada distribucija stvarnih grešaka nije simetrična [8].

3.4.5 Srednja apsolutna kalibraciona greška

Srednja apsolutna kalibraciona greška (eng. *Mean Absolute Calibration Error*, MACE) mjeri prosječno apsolutno odstupanje između predviđenih vjerojatnosti (razina pouzdanosti) i empirijskih frekvencija pokrivenosti kroz cijeli raspon razina pouzdanosti [23]:

$$MACE = \frac{1}{M} \sum_{j=1}^M |p_j - \hat{p}_j| \quad (3.12)$$

gdje je M broj ravnomjerno raspoređenih razina pouzdanosti $p_1 < p_2 < \dots < p_M$ u intervalu $[0, 1]$, a $\hat{p}_j$ empirijska frekvencija pokrivenosti na razini p_j :

$$\hat{p}_j = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[y_i \leq F_i^{-1}(p_j)] \quad (3.13)$$

gdje je $F_i^{-1}(p_j)$ p_j -ti kvantil prediktivne distribucije za uzorak i . MACE predstavlja srednju apsolutnu varijantu porodice regresijskih kalibracionih metrika koju su uveli Kuleshov et al. [22], a koju su kasnije formalizirali Chung et al. [23] kao alternativu kvadratnoj (RMS) varijanti iste porodice metrika. Za razliku od klasične *Expected Calibration Error* metrike iz literature o klasifikaciji, koja se računa *binning*-om predviđenih vjerojatnosti klasa i poređenjem s empirijskom tačnošću po binu, MACE je definirana direktno na nivou razina pouzdanosti prediktivnih intervala, što je prikladnije za regresijske UQ zadatke poput onog u ovom radu.

MACE vrijednost blizu nule ukazuje na dobro kalibriran model, dok visoka MACE ukazuje na sistematsko odstupanje između iskazane i stvarne pouzdanosti. Vizualna reprezentacija kalibracije postiže se *reliability dijagramom* (eng. *reliability diagram* ili *calibration plot*), koji prikazuje $\hat{p}_j$ kao funkciju p_j – savršeno kalibriran model odgovara dijagonali $\hat{p}_j = p_j$. Odstupanja ispod dijagonale indiciraju *overconfidence*, a iznad dijagonale *underconfidence* [8, 22]. Ove metrike izračunavaju se funkcijama prikazanim u Programu 7.7.

4. Metode kvantifikacije nesigurnosti

4.1 Monte Carlo Dropout

Dropout je izvorno uveden kao tehnika regularizacije u dubokim neuronskim mrežama, s ciljem smanjenja prekomjernog prilagođavanja (eng. *overfitting*) [18]. U standardnoj primjeni, dropout nasumično isključuje određeni udio neurona tokom treninga, a deaktivira se u fazi inferencije. Gal i Ghahramani [9] pokazali su da zadržavanje dropouta aktivnim i tokom faze inferencije ima dublje teorijsko opravdanje: takva mreža predstavlja aproksimaciju Bayesovskog zaključivanja nad dubokim Gaussovskim procesom. Ova interpretacija omogućava ekstrakciju mjere nesigurnosti iz standardnih dropout mreža bez ikakve izmjene arhitekture ili postupka treninga.

Formalno, neka je $\omega = \{\mathbf{W}_l\}_{l=1}^L$ skup težina mreže s L slojeva. Gal i Ghahramani pokazuju da minimizacija standardnog dropout gubitka:

$$\mathcal{L}_{\text{dropout}} = \frac{1}{N} \sum_{i=1}^N \mathcal{E}(y_i, \hat{y}_i) + \lambda \sum_{l=1}^L (\|\mathbf{W}_l\|_2^2 + \|\mathbf{b}_l\|_2^2) \quad (4.1)$$

odgovara minimizaciji KL-divergencije između varijacione distribucije $q(\omega)$ i posteriorne distribucije nad težinama dubokog Gaussovskog procesa [9]. Varijaciona distribucija parametrizirana je tako da su kolone matrica težina nasumično postavljene na nulu s vjerovatnoćom $1 - p_i$ za sloj i , što je ekvivalentno Bernoulijevom uzorkovanju u dropout proceduri.

Ključna inovacija metode leži u načinu izvođenja inferencije. Umjesto standardnog pristupa u kojemu se dropout isključuje i koriste usrednjene težine, MC Dropout izvodi T stohastičkih prolaza kroz mrežu uz aktivne dropout slojeve. Svaki prolaz koristi drugačiji realizirani skup binarnih maski, čime se efektivno uzorkuju različiti modeli iz varijacione distribucije $q(\omega)$. Prediktivna srednja vrijednost i varijansa procjenjuju se kao:

$$\mathbb{E}[y^*] \approx \frac{1}{T} \sum_{t=1}^T \hat{y}_t^*, \quad \text{Var}[y^*] \approx \tau^{-1} + \frac{1}{T} \sum_{t=1}^T \hat{y}_t^{*2} - \mathbb{E}[y^*]^2 \quad (4.2)$$

gdje je τ^{-1} preciznost modela, a $\hat{y}_t^*$ predikcija iz t -tog stohastičkog prolaza [9].

Važno je naglasiti da standardna devijacija dobijena iz T MC Dropout uzoraka nije čisto epistemička nesigurnost. Ukupna prediktivna nesigurnost sadrži i epistemičku i aleatoričku komponentu [6], a MC Dropout u svojoj osnovnoj formulaciji ne razdvaja te dvije komponente, procijenjeni interval odražava kombinovani efekt nesigurnosti modela i inherentne varijabilnosti podataka. Precizna dekompozicija zahtijeva arhitekturu s dvije zasebne izlazne glave koje direktno uče heteroscedastičnu aleatoričku varijansu [6], što nije primijenjeno u ovom radu. Umjesto toga, u sekciji posvećenoj hibridnoj Bayesovskoj neuronskoj mreži primjenjuje se aproksimativna heuristička metoda dekompozicije, koja se zasniva na istom principu stohastičkog uzorkovanja korištenom i kod MC Dropout metode [8].


U implementiranom modelu, MC Dropout primjenjuje se na LSTM arhitekturu koja se sastoji od dva LSTM sloja (sa 64 i 32 jedinice) i dva gusta sloja, pri čemu su dropout slojevi s vjerojatnošću $p = 0.3$ smješteni između LSTM i gustih slojeva. Viša stopa dropouta povećava raznolikost stohastičkih uzoraka i time širi procijenjene intervale nesigurnosti, ali istovremeno može degradirati prediktivnu tačnost jer se u svakom prolazu deaktivira veći udio informativnih neurona. Odabir vrijednosti p zasniva se na jednodimenzionalnoj analizi osjetljivosti, provedenoj na validacionom skupu uz tri nezavisna slučajna sjemena po vrijednosti. Postupak ove analize ilustrovan je na primjeru dropout stope u Programu 7.9. Budući da MC Dropout i Deep Ensemble dijele identičnu LSTM arhitekturu s istim dropout slojevima, analiza je provedena jednom za obje metode. Tabela 4.1 prikazuje dobijene vrijednosti RMSE-a, pokrivenosti prediktivnih intervala (CP) i srednje širine intervala (MIW) na validacionom skupu, pri čemu su sve tri metrike prikazane kao $\text{mean} \pm \text{std}$ preko tri nezavisna sjemena, radi konzistentnog uvida u varijabilnost procjene svake od njih.

p	RMSE	CP	MIW
0.1	12.07 ± 0.09	0.59 ± 0.02	19.16 ± 0.81
0.2	12.33 ± 0.13	0.75 ± 0.03	28.32 ± 1.06
0.3	12.06 ± 0.17	0.75 ± 0.04	28.47 ± 4.39
0.4	12.23 ± 0.21	0.77 ± 0.02	32.45 ± 4.59
0.5	12.50 ± 0.06	0.80 ± 0.04	35.10 ± 4.66

Tabela 4.1: Osjetljivost zajedničke LSTM arhitekture (dropout slojevi korišteni u MC Dropout i Deep Ensemble metodama) na dropout stopu p .

RMSE ostaje u relativno uskom rasponu kroz sve testirane vrijednosti, bez jasnog monotonog trenda: najniža vrijednost bilježi se pri $p = 0.3$, praktično izjednačena sa $p = 0.1$, razlika od svega 0.002 zanemarljiva je u odnosu na standardne devijacije oba mjerenja, što ukazuje da tačnost modela nije snažno osjetljiva na p u ovom opsegu. Pokrivenost prediktivnih intervala generalno raste s p , uz blagi izuzetak između $p = 0.2$ i $p = 0.3$, gdje je pad od svega 0.002 znatno manji od standardne devijacije oba mjerenja, te stoga ne predstavlja stvaran obrat trenda već statistički šum. Nijedna testirana vrijednost ne dostiže nominalni cilj od 95% pokrivenosti; MC Dropout je u ovom opsegu sistematski *underconfident*, što je dodatno razmotreno u kontekstu konformne kalibracije. Vrijednost $p = 0.3$ odabrana je jer, prema usvojenom kriterijumu izbora (najniža srednja vrijednost RMSE-a na validacionom skupu, uz prednost računski jeftinijoj vrijednosti kada je razlika između kandidata manja od jedne standardne devijacije), praktično dijeli najbolji RMSE sa $p = 0.1$, dok istovremeno nudi bolju pokrivenost intervala. Ovaj izbor je u skladu i s uobičajenim vrijednostima u literaturi za primjenu MC Dropouta na sekvencijalnim podacima [8, 9].

Tokom inferencije, za svaki motor iz testnog skupa izvodi se $T = 100$ stohastičkih prolaza, a srednja vrijednost distribucije predikcija koristi se kao konačna tačkasta predikcija dok standardna devijacija kvantificira ukupnu nesigurnost. Funkcija koja ovo provodi data je u prilogu 7.4. Jedna od ključnih praktičnih prednosti MC Dropout metode jeste njena jednostavnost implementacije: ne zahtijeva izmjenu arhitekture ni postupka treninga u odnosu na deterministički model, već isključivo promjenu načina inferencije [8, 9]. Arhitekture svih triju implementiranih metoda prikazane su na Slici 4.1.



Slika 4.1: Usporedni prikaz arhitektura triju implementiranih metoda kvantifikacije nesigurnosti: MC Dropout, Deep Ensemble i Hibridni BNN.

4.2 Deep Ensemble

Metoda dubokih ansambala (eng. *Deep Ensembles*) zasniva se na treniranju K nezavisnih instanci iste neuronske arhitekture, pri čemu svaki model polazi od drugačije nasumične inicijalizacije parametara [10]. Intuicija metode oslanja se na dobro poznatu empirijsku opservaciju da ansambl modela u prosjeku nadmašuje pojedinačni model po tačnosti predikcije [19], no Lakshminarayanan et al. pokazuju da isti mehanizam raznolikosti koji poboljšava tačnost istovremeno nosi i korisnu informaciju o nesigurnosti: kada se modeli u ansamblu međusobno slažu, nesigurnost je niska; kada se razilaze, nesigurnost je visoka.

Za razliku od MC Dropout metode koja uzorkuje različite podmreže jednog istog treniranog modela, svaki član ansambla prolazi kroz kompletan i nezavisan postupak treniranja. Budući da je gubitak neuronskih mreža nekonveksan, različite inicijalizacije vode do različitih lokalnih minimuma u prostoru parametara, što rezultira modelima koji su funkcionalno raznolikiji nego što bi to bili uzorci iz jedne varijacione distribucije [10]. Upravo ova funkcionalna raznolikost čini ansambl robusnijim na primjere izvan distribucije treniranja (eng. *out-of-distribution*) u poređenju s metodama koje dijele jednu mrežu.

Neka je K broj nezavisno treniranih članova ansambla, a M broj stohastičkih prolaza koje svaki član generiše tokom inferencije uz aktivan dropout. Za ulaz $\mathbf{x}$, član k generiše skup predikcija $\{\hat{y}_{k,m}(\mathbf{x})\}_{m=1}^M$. Konačna predikcija i mjera nesigurnosti računaju se kao srednja vrijednost i

standardna devijacija preko svih $K \times M$ uzoraka:

$$\hat{\mu}(\mathbf{x}) = \frac{1}{KM} \sum_{k=1}^K \sum_{m=1}^M \hat{y}_{k,m}(\mathbf{x}), \quad \hat{\sigma}^2(\mathbf{x}) = \frac{1}{KM} \sum_{k=1}^K \sum_{m=1}^M (\hat{y}_{k,m}(\mathbf{x}) - \hat{\mu}(\mathbf{x}))^2 \quad (4.3)$$

Iz perspektive kvantifikacije nesigurnosti, varijansa ansambla $\hat{\sigma}^2(\mathbf{x})$ mjeri neslaganje modela i primarno odražava epistemičku nesigurnost, tj. nesigurnost koja nastaje jer različite inicijalizacije pronalaze različite hipoteze konzistentne s trening skupom [8, 10]. Za razliku od standardne Deep Ensemble formulacije u kojoj svaki član daje jednu determinističku predikciju, u ovoj implementaciji dropout ostaje aktivan i tokom inferencije, pa svaki član sam po sebi generiše distribuciju predikcija umjesto jedne tačke. Ukupna varijansa $\hat{\sigma}^2(\mathbf{x})$ time obuhvata dva izvora varijabilnosti: varijabilnost između članova ansambla, koja potječe od različitih inicijalizacija i različitih lokalnih minimuma (epistemička komponenta u klasičnom smislu), i varijabilnost unutar svakog člana zbog dropout uzorkovanja, analognu mehanizmu koji koristi MC Dropout. Ova varijacija metode, koja kombinira diverzitet ansambla s MC Dropout uzorkovanjem po članu, odabrana je iz dva razloga: prvo, osigurava jednak broj uzoraka ($KM = 100$) po ulazu za sve tri implementirane UQ metode, čime se izbjegava nenamjeravani uticaj razlike u veličini uzorka pri poređenju širine intervala nesigurnosti; drugo, procjena standardne devijacije iz samo $K = 5$ tačkastih predikcija bi bila statistički znatno nestabilnija od procjene iz $KM = 100$ uzoraka, budući da varijansa procjenitelja standardne devijacije opada s brojem uzoraka. Ova dva izvora nisu odvojena u jednačini 4.3, već doprinose zajedničkoj varijansi. Zbog ove mješavine izvora, čista dekompozicija na epistemičku i aleatoričku nesigurnost u okviru ovog ansambla nije provedena u ovom radu; takva dekompozicija bi zahtijevala da svaki član zasebno i eksplicitno modelira heteroscedastičnu varijansu, odvojeno od dropout uzorkovanja.

U implementiranom modelu, ansambl se sastoji od $K = 5$ nezavisno treniranih LSTM mreža identične arhitekture kao i u MC Dropout slučaju: dva LSTM sloja (sa 64 i 32 jedinice), dropout slojevi s vjerovatnoćom $p = 0.3$ i dva gusta sloja. Vrijednost $p = 0.3$ ista je kao u MC Dropout arhitekturi; osjetljivost na ovaj parametar analizirana je zajednički za obje metode u Sekciji 4.1. Svaki model inicijaliziran je drugačijim slučajnim sjemenom, a treniran je nezavisno na istom trening skupu. Tokom inferencije, za svaki motor iz testnog skupa prikuplja se po $M = 20$ stohastičkih prolaza (uz aktivni dropout) od svakog od $K = 5$ članova, što daje ukupno $KM = 100$ uzoraka po ulazu, isti broj kao i u MC Dropout slučaju, čime se osigurava uporedivost procijenjenih intervala nesigurnosti između metoda. Petlja treniranja i agregacije prikazana je u Programu 7.5.

Glavna praktična prednost ansambla u odnosu na MC Dropout jeste veća robusnost procjene nesigurnosti: budući da dio raznolikosti dolazi iz funkcionalno različitih modela a ne samo iz različitih dropout maski iste mreže, ansambl je teorijski manje podložan sistematskim greškama u procjeni nesigurnosti [10]. Cijena ove prednosti je računska: treniranje K modela zahtijeva K puta više vremena i memorije nego treniranje jednog modela, što može biti ograničavajući faktor u primjenama s velikim arhitekturama ili ograničenim računskim resursima [8].

4.3 Hibridna Bayesovska neuronska mreža

Bayesovska neuronska mreža (eng. *Bayesian Neural Network*, BNN) predstavlja fundamentalno drugačiji pristup kvantifikaciji nesigurnosti u odnosu na prethodne dvije metode. Umjesto da nesigurnost procjenjuje posredno, kroz stohastičku inferenciju jednog modela ili raznolikost skupa modela, BNN direktno modelira distribuciju nad parametrima mreže [11, 16]. Svaka težina w nije fiksna skalarna vrijednost već slučajna varijabla opisana distribucijom, tipično

Gaussovskom: $q(w | \theta) = \mathcal{N}(w; \mu, \sigma^2)$. Epistemička nesigurnost tada direktno proizlazi iz širine tih distribucija, parametri za koje je model vidio malo podataka imat će širu distribuciju, a time i veći doprinos ukupnoj nesigurnosti predikcije.

Tačno Bayesovsko zaključivanje zahtijeva računanje posteriorne distribucije $p(\omega | \mathcal{D})$, što je za neuronske mreže računski neizvedivo. Standardni pristup je varijaciona inferencija (eng. *variational inference*), u kojoj se uvodi parametrizirana varijaciona distribucija $q(\omega | \theta)$ i minimizira njezina KL-divergencija prema posteriornoj distribuciji [11, 17]. Ovo je ekvivalentno maksimizaciji donje granice log-vjerodostojnosti (eng. *Evidence Lower Bound*, ELBO):

$$\mathcal{L}(\theta) = \mathbb{E}_{q(\omega|\theta)} [\log p(\mathcal{D} | \omega)] - \text{KL}(q(\omega | \theta) \| p(\omega)) \quad (4.4)$$

gdje prvi član nagrađuje model koji dobro opisuje podatke, a drugi član, KL-divergencija prema apriori distribuciji $p(\omega)$ djeluje kao regularizator koji sprječava previše sigurne distribucije [11].

Gradijenti ovog cilja računaju se primjenom reparametrizacijskog trika (eng. *reparametrization trick*) [24]: umjesto direktnog uzorkovanja $w \sim q(w | \mu, \sigma)$, što bi prekinulo tok gradijenata, težina se izražava kao deterministička transformacija uzorka iz standardnog normala:

$$w = \mu + \sigma \cdot \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, 1) \quad (4.5)$$

gdje su μ i σ (preciznije, ρ iz kojeg se $\sigma = \log(1 + e^\rho)$ dobija softplus transformacijom radi osiguranja pozitivnosti) parametri koji se uče standardnom propagacijom greške. Ovaj trik omogućava da stohastički prolaz kroz mrežu bude u potpunosti diferencijabilan [11].

Implementirani model koristi pristup koji se u literaturi opisuje terminima *partially Bayesian neural network* [14] ili *variational output layer model* [21]. Oba termina opisuju istu arhitekturnu ideju: samo dio mreže tretira se probabilistički, dok ostatak ostaje deterministički. Jospin et al. [14] pod terminom *partially Bayesian neural network* podrazumijevaju mreže u kojima se varijaciona inferencija primjenjuje isključivo na podskup slojeva, najčešće izlazne, dok Benker et al. [21] koriste termin *variational output layer model* kako bi naglasili da je probabilistički tretman ograničen na izlazni dio mreže koji direktno producira predikciju. U ovom radu LSTM slojevi ostaju deterministički, dok se varijaciona inferencija primjenjuje isključivo na gustim slojevima putem prilagođenog sloja `DenseVariational` (kompletna implementacija ovog prilagođenog sloja data je u prilogu 7.6), što odgovara opisu iz oba navedena rada.

Ovakav hibridni karakter arhitekture svjesni je kompromis između računske složenosti i probabilističkog modeliranja. Potpuno varijacioni LSTM slojevi zahtijevali bi distribuiranje nad znatno većim brojem parametara, budući da bi svaka od ulaznih, zaboravnih, čelijskih i izlaznih matrica vrata morala biti zamijenjena distribucijom, što značajno otežava optimizaciju uz minimalni dobitak na skupu podataka ove veličine [8]. Termin *hibridna Bayesovska neuronska mreža*, koji se koristi u ovom radu, naglašava upravo taj miješani karakter i eksplicitno signalizira da se ne radi o punom BNN-u u strogom smislu. Teorijsko opravdanje za ovakav odabir leži u tome da epistemička nesigurnost modela primarno dolazi do izražaja u izlaznim slojevima koji mapiraju naučene reprezentacije u predikciju, dok deterministički rekurentni slojevi služe kao enkoder sekvencijalnih obrazaca za koje probabilistički tretman donosi manji doprinos [20].

Konačna arhitektura sastoji se od dva deterministička LSTM sloja (sa 64 i 32 jedinice) s dropout regularizacijom ($p = 0.4$), iza kojih slijede dva varijaciona gusta sloja s 32 jedinice i jednom izlaznom jedinicom. Odabir vrijednosti p zasniva se na jednodimenzionalnoj analizi osjetljivosti, provedenoj na validacionom skupu uz tri nezavisna slučajna sjemena po vrijednosti, analogno postupku opisanom u Sekciji 4.1 za MC Dropout i Deep Ensemble arhitekturu. Tabela 4.2 prikazuje dobijene vrijednosti RMSE-a, pokrivenosti prediktivnih intervala (CP) i srednje širine intervala (MIW) na validacionom skupu, pri čemu su sve tri metrike prikazane kao $\text{mean} \pm \text{std}$.

p	RMSE	CP	MIW
0.1	11.92 ± 0.13	0.65 ± 0.02	20.29 ± 1.35
0.2	12.17 ± 0.30	0.73 ± 0.03	27.39 ± 1.23
0.3	12.27 ± 0.36	0.78 ± 0.02	33.33 ± 0.98
0.4	12.25 ± 0.27	0.81 ± 0.03	35.28 ± 4.02

Tabela 4.2: Osjetljivost hibridnog BNN modela na dropout stopu p u determinističkim LSTM slojevima.

Za razliku od zajedničke LSTM grane, gdje pokrivenost pokazuje nemonotono ponašanje, kod hibridnog BNN-a pokrivenost prediktivnih intervala raste konzistentno s p , dok RMSE ostaje praktično stabilan iznad $p = 0.2$. Vrijednost $p = 0.4$ odabrana je jer postiže najvišu pokrivenost od svih testiranih vrijednosti bez mjerljivog pogoršanja RMSE-a u odnosu na niže vrijednosti. Vrijedno je napomenuti da je pri $p = 0.4$ standardna devijacija širine intervala znatno veća nego kod nižih vrijednosti p , što ukazuje na blago povećanu varijabilnost procjene širine intervala uz ovu dropout stopu, iako to ne utiče na odabir konačne vrijednosti p . Ovo je veća vrijednost od one korištene u zajedničkoj LSTM grani MC Dropout i Deep Ensemble metoda, što je u skladu s hibridnim karakterom arhitekture: budući da varijaciona inferencija obuhvata isključivo izlazne guste slojeve, deterministički LSTM enkoder ne doprinosi epistemičkoj nesigurnosti modela [14]. Veći dropout u determinističkom dijelu mreže djelimično nadomješta ovaj nedostatak, povećavajući ukupnu varijabilnost predikcija i time doprinoseći boljoj kalibraciji intervala nesigurnosti. Broj od 32 jedinice u varijacionim slojevima odabran je kao kompromis između ekspresivnosti modela i stabilnosti varijacione inferencije: manji slojevi smanjuju broj varijacionih parametara koje optimizator mora naučiti, čime se ubrzava konvergencija i smanjuje rizik od kolapsa posteriorne distribucije prema apriori distribuciji. Ukupni gubitak koji se minimizira tokom treninga kombinira srednju kvadratnu grešku predikcije i KL-divergenciju varijacionih slojeva, skaliranu veličinom trening skupa:

$$\mathcal{L}_{\text{total}} = \text{MSE}(\hat{y}, y) + \frac{1}{N} \text{KL}(q(\omega \mid \theta) \parallel p(\omega)) \quad (4.6)$$

Skaliranje KL-divergencije faktorom $1/N$, gdje je N veličina trening skupa, osigurava da regularizacijski doprinos ostane razmjeran doprinosu podataka bez obzira na veličinu skupa [11]. Bez ovog skaliranja, KL član bi dominirao gubitkom na velikim skupovima podataka, što bi rezultiralo pretjerano širokim distribucijama težina i time precijenjenom nesigurnošću, tj. *underconfidence*-om modela.

Tokom inferencije, za svaki uzorak iz testnog skupa izvodi se $T = 100$ stohastičkih prolaza kroz mrežu, pri čemu svaki prolaz uzorkuje drugačiju realizaciju težina varijacionih slojeva. Srednja vrijednost tih prolaza daje tačkastu predikciju RUL-a, dok standardna devijacija kvantificira nesigurnost. Zajedno s MC Dropout metodom, hibridni BNN omogućava aproksimativnu dekompoziciju ukupne nesigurnosti na epistemičku i aleatoričku komponentu, budući da oba modela generiraju nesigurnost kroz stohastičko uzorkovanje iz jedne naučene distribucije, za razliku od Deep Ensemble metode, čija je varijansa hijerarhijska smjesa neusaglašenosti modela i unutrašnjeg dropout uzorkovanja. Ova dekompozicija detaljnije je razrađena u poglavlju o eksperimentalnoj evaluaciji.

5. Skup podataka i preprocesiranje

5.1 CMAPSS skup podataka

Komercijalna modularna aero-pogonska systemska simulacija (eng. *Commercial Modular Aero-Propulsion System Simulation*, CMAPSS) razvijena je u NASA-i s ciljem generiranja realističnih podataka o degradaciji mlaznih motora za potrebe istraživanja prognostike i upravljanja zdravljem sistema [3]. Simulacijski alat modelira turbofan motor klase 90 000 funti potiska i omogućava variranje parametara stanja pojedinih rotacionih komponenti: ventilatora, kompresora niskog pritiska (LPC), kompresora visokog pritiska (HPC), turbine visokog pritiska (HPT) i turbine niskog pritiska (LPT), čime se simuliraju različiti scenariji degradacije [3].

Skup podataka je organiziran u četiri podskupa (FD001–FD004) koji se razlikuju po broju operativnih uvjeta i tipova kvarova. U ovom radu koristi se isključivo podskup FD001, koji modelira degradaciju *HPC* modula pod jednim operativnim uvjetom i jednim tipom kvara. Trening skup sadrži trajektorije 100 motora praćenih od inicijalnog stanja do potpunog otkaza, dok test skup sadrži 100 motora čije su trajektorije prekinute u nepoznatom trenutku prije otkaza.

Svaki vremenski korak (ciklus) sadrži tri operativna parametra i 21 senzorsko mjerenje. Operativni parametri opisuju uvjete leta (visina, Machov broj, postavka gasa), dok senzorska mjerenja obuhvataju fizičke veličine duž plinskog trakta motora: temperature i pritiske na ulazu i izlazu kompresora i turbine, brzine vrtnje rotora, omjere protoka zraka i goriva te efikasnosti pojedinih komponenti. Sve ove veličine tipično su dostupne u sistemima za praćenje stanja stvarnih avionskih motora, što CMAPSS čini realističnom simulacijskom osnovom za razvoj algoritama prediktivnog održavanja. Tabela 5.1 daje pregled ključnih karakteristika korištenog podskupa.

Tabela 5.1: Karakteristike CMAPSS FD001 podskupa

Karakteristika	Vrijednost
Broj motora (trening)	100
Broj motora (test)	100
Operativni uvjeti	1
Tip kvara	1 (HPC degradacija)
Broj operativnih parametara	3
Broj senzora	21
Raspon životnog vijeka (trening)	128–362 ciklusa

Važno je naglasiti strukturalnu razliku između trening i test skupa koja direktno motivira potrebu za pretprocesiranjem. U trening skupu, trajektorija svakog motora prati se od prvog ciklusa do trenutka potpunog otkaza, što znači da su labela RUL-a poznate za svaki vremenski korak. U test skupu, trajektorije su prekinute u nepoznatom trenutku prije otkaza, a za svaki motor dostupna je samo jedna referentna RUL vrijednost u trenutku prekida, koja se koristi isključivo za evaluaciju. Ova asimetrija između trening i test skupa, potpune trajektorije nasuprot parcijalnih, znači da model mora naučiti procjenu RUL-a isključivo iz historije senzorskih mjerenja, bez eksplicitnog znanja o tome koliko daleko je motor od otkaza u trenutku predikcije.


CMAPSS FD001 predstavlja de facto standardni *benchmark* za evaluaciju metoda predikcije RUL-a u literaturi o prediktivnom održavanju [2, 12, 13]. Zahvaljujući javnoj dostupnosti i dobro definiranoj eksperimentalnoj postavci, ovaj podskup omogućava direktnu usporedbu rezultata između različitih pristupa, što ga čini idealnim okvirom za evaluaciju metoda kvantifikacije nesigurnosti implementiranih u ovom radu.

5.2 Eksplorativna analiza podataka

Prije pretprocesiranja i modeliranja provedena je eksplorativna analiza podataka (eng. *Exploratory Data Analysis*, EDA) s ciljem razumijevanja strukture seta podataka, identifikacije informativnih senzora i vizualizacije obrazaca degradacije motora. Rezultati ove analize direktno su informirali sve naredne korake pretprocesiranja.

5.2.1 Distribucija životnog vijeka motora


Analiza distribucije ukupnog broja ciklusa po motoru, prikazana na Slici 5.1, otkriva značajnu varijabilnost životnog vijeka motora u trening skupu: raspon je od 128 do 362 ciklusa, uz prosječni životni vijek od 206.3 ciklusa i standardnu devijaciju od oko 46 ciklusa. Ova varijabilnost nije slučajna, u skladu je s opisom generativnog procesa skupa podataka u kojem su parametri degradacije (a_k i b_k u jednačini zdravstvenog indeksa) nasumično odabrani za svaki motor iz normalne distribucije [3]. Direktna posljedica ove varijabilnosti jest da deterministički model koji predviđa samo tačkastu vrijednost RUL-a ne može adekvatno modelirati prirodnu nepredvidivost procesa degradacije, što je temeljni argument za primjenu metoda kvantifikacije nesigurnosti.



Slika 5.1: Distribucija životnog vijeka za 100 motora u trening skupu CMAPSS FD001.

5.2.2 Distribucija RUL labele


Slika 5.2 prikazuje distribuciju sirovih RUL vrijednosti (bez ograničenja) i distribuciju nakon primjene gornje granice od 125 ciklusa. Sirova distribucija pokazuje izraženu neravnomjernost: veliki broj uzoraka ima visoke vrijednosti RUL-a koje odgovaraju ranim fazama rada motora, u kojima su senzorski signali praktično identični signalima zdravog sistema. Primjena granice od 125 ciklusa rezultira ujednačenijom distribucijom i eksplicitno modelira pretpostavku o *piecewise linear* degradaciji: model se trenira na prepoznavanju isključivo one faze rada u kojoj su znakovi degradacije mjerljivo vidljivi u podacima. Ova transformacija detaljno je obrazložena u Sekciji 5.4.



Slika 5.2: Usporedba distribucije RUL labele bez ograničenja (lijevo) i s ograničenjem na 125 ciklusa (desno). Clipping rezultira ujednačenijom distribucijom i fokusira model na kritičnu fazu degradacije.

5.2.3 Identifikacija konstantnih senzora


Inicijalna analiza varijabilnosti senzorskih mjerenja kroz sve cikluse i motore, prikazana na Slici 5.3, otkrila je da sedam od 21 senzora ne pokazuje praktično nikakvu varijansu (standardna devijacija ispod praga od 0.01): *sensor_1*, *sensor_5*, *sensor_6*, *sensor_10*, *sensor_16*, *sensor_18* i *sensor_19*. Konstantni senzori ne nose nikakvu informaciju o stanju degradacije motora, a njihovo uključivanje u model uvodi šum bez doprinosa prediktivnoj sposobnosti. Ovi senzori se eliminiraju iz daljnje analize.



Slika 5.3: Standardna devijacija senzorskih mjerenja u trening skupu. Senzori čija je standardna devijacija ispod praga od 0.01 identificirani su kao konstantni i eliminiraju se iz skupa atributa.


5.2.4 Korelacijska analiza

Za preostalih 14 senzora i 3 operativna parametra izračunata je Pearsonova korelacija [25] s RUL labelom (uz primijenjenu granicu od 125 ciklusa). Rezultati su prikazani na Slici 5.4. Analiza je pokazala da većina preostalih senzora ima statistički značajnu linearnu vezu s RUL-om: `sensor_11` pokazuje najsnažniju negativnu korelaciju (vrijednosti rastu kako motor degradira), dok `sensor_12` pokazuje izraženu pozitivnu korelaciju (vrijednosti opadaju zajedno s padom RUL-a). Za senzore sa slabijim linearnim odnosom s RUL-om model mora naučiti kompleksnije, nelinearne obrasce iz sekvencijalnih podataka, što je upravo snaga LSTM arhitekture.



Slika 5.4: Pearsonova korelacija senzora s RUL labelom nakon uklanjanja konstantnih senzora.

Dodatni uvid u ponašanje najrelevantnijih senzora pruža vizualizacija njihovih degradacijskih trajektorija. Slika 5.5 prikazuje vremenske serije triju senzora s najvećom apsolutnom korelacijom s RUL-om za nasumični uzorak od pet motora. Vizualizacija potvrđuje jasne trendove trošenja, ali uz primjetan šum i različite brzine propadanja kod pojedinih motora. Ta varijabilnost, tj. razlika u nagibu i trajanju krivulja degradacije, ključni je motiv za kvantifikaciju nesigurnosti: svaki motor ima unikatan profil degradacije, zbog čega se deterministička predikcija RUL-a ne može smatrati dovoljnom za donošenje sigurnih odluka o održavanju.



Slika 5.5: Vremenske serije triju najinformativnijih senzora za pet nasumično odabranih motora. Svaka linija odgovara jednom motoru. Razlike u nagibu i dužini trajektorija odražavaju inherentnu varijabilnost procesa degradacije.

5.3 Odabir relevantnih senzora

Na temelju EDA, set značajki je reduciran sa originalne 24 varijable (3 operativna parametra + 21 senzor) na 17 varijabli eliminacijom sedam konstantnih senzora identificiranih u Sekciji 5.2. Tri operativna parametra zadržana su radi konzistentnosti s praksom u literaturi [12, 13], iako je njihova varijansa u FD001 podskupu minimalna zbog jednog operativnog uvjeta. Konačni set značajki obuhvata:

$$\mathcal{F} = \{\text{op}_1, \text{op}_2, \text{op}_3, s_2, s_3, s_4, s_7, s_8, s_9, s_{11}, s_{12}, s_{13}, s_{14}, s_{15}, s_{17}, s_{20}, s_{21}\} \quad (5.1)$$

Redukcija dimenzionalnosti s 24 na 17 varijabli smanjuje računsku složenost i eliminira šum bez gubitka informacije relevantne za predikciju RUL-a [26].

5.4 Konstrukcija RUL labele

Za svaki motor u trening skupu, RUL u ciklusu t definira se kao razlika između ukupnog broja ciklusa T i trenutnog ciklusa t :

$$\text{RUL}(t) = T - t \quad (5.2)$$

Direktna primjena ove formule rezultira velikim vrijednostima RUL-a u ranoj fazi životnog vijeka, u kojoj su fizički procesi degradacije teško uočljivi u senzorskim podacima. Ako se motor ponaša praktično identično zdravom sistemu kroz prvih 100–200 ciklusa, nema smisla razlikovati RUL od 300 ciklusa od RUL-a od 200 ciklusa: senzorski signali su u oba slučaja gotovo isti. Forsiranje modela da nauči ovu distinkciju uvodi šum u proces treninga bez informacijskog dobitka.

Problem se adresira primjenom *piecewise linear* modela degradacije [12]:

$$\text{RUL}_{\text{cap}}(t) = \min(\text{RUL}(t), C) \quad (5.3)$$

gdje je C gornja granica koja definira horizont prognostike. Vrijednost $C = 125$ ciklusa odabrana je kao standardna vrijednost za CMAPSS FD001 u literaturi [12, 13] iz nekoliko međusobno konzistentnih razloga.

Prvo, minimalni životni vijek motora u trening skupu iznosi 128 ciklusa (Slika 5.1), što znači da je $C = 125 < 128$ i da svaki motor u trening skupu nužno prolazi kroz fazu u kojoj je $\text{RUL}(t) < C$. Time je garantovano da model za svaki primjer u skupu dobiva labelu iz kritične zone degradacije, a ne samo za motore s kraćim životnim vijekom. Da je C odabran veći od minimalnog životnog vijeka, dio motora ne bi imao ni jedan primjer s labelom jednakom stvarnom RUL-u, što bi narušilo konzistentnost trening skupa. Drugo, granica od 125 ciklusa empirijski odgovara trenutku od kojeg senzorski signali pokazuju statistički mjerljiv trend degradacije, što je potvrđeno vizualizacijom degradacijskih trajektorija u Sekciji 5.2.4. Ispod ovog praga, signali poput `sensor_11` i `sensor_4` pokazuju konzistentan monotoni trend koji LSTM može iskoristiti za predikciju; iznad njega, signali su pretežno stacionarni i ne nose prediktivnu informaciju o preostalom vijeku. Treće, fiksiranjem gornje granice na 125 postiže se ujednačenija distribucija labele u trening skupu, što olakšava optimizaciju modela jer se izbjegava dominacija primjera s velikim RUL vrijednostima koji nemaju odgovarajući senzorski signal. Raspon labele u trening skupu nakon primjene granice iznosi $[0, 125]$ ciklusa (Program 7.2).

5.5 Normalizacija i kreiranje sekvenci

Normalizacija

Sve ulazne varijable normalizirane su na interval $[0, 1]$ primjenom min-max normalizacije:

$$x_{\text{norm}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (5.4)$$

Parametri normalizacije određeni su isključivo na trening skupu, a isti parametri primijenjeni su na test skup, čime se sprečava curenje informacija (eng. *data leakage*) [26]. Normalizacija je neophodna jer LSTM mreže, kao gradijentne metode, osjetljive su na razlike u skalama ulaznih varijabli.

Kreiranje vremenskih sekvenci

Za svaki motor, u svakom ciklusu t , formira se ulazna sekvenca dužine W primjenom pristupa kliznog prozora (eng. *sliding window*):

$$\mathbf{X}_t = [\mathbf{x}_{t-W+1}, \mathbf{x}_{t-W+2}, \dots, \mathbf{x}_t] \in \mathbb{R}^{W \times |\mathcal{F}|} \quad (5.5)$$

gdje je $\mathbf{x}_t \in \mathbb{R}^{|\mathcal{F}|}$ vektor ulaznih varijabli u ciklusu t . Ciljna labela za sekvencu $\mathbf{X}_t$ jest $\text{RUL}_{\text{cap}}(t)$.

Prije generisanja vremenskih sekvenci, originalni trening skup CMAPSS FD001 podijeljen je na trening i validacioni podskup u omjeru 80/20, koristeći grupnu podjelu: skup jedinstvenih identifikatora motora nasumično je podijeljen korištenjem `train_test_split` funkcije, nakon čega su sekvence generisane zasebno za svaki podskup motora. Ovakva podjela na nivou cijelih motora prije generisanja sekvenci, a ne podjela već generisanih sekvenci, nužna je kako bi se izbjeglo curenje podataka: budući da susjedne sekvence istog motora dijele 39 od 40 vremenskih koraka, podjela na nivou pojedinačnih sekvenci rezultirala bi time da gotovo identične sekvence istog motora završe i u trening i u validacionom skupu, što bi vodilo lažno optimističnoj procjeni performansi modela na validaciji. Rezultat podjele je 80 trening motora i 20 validacionih motora, odnosno 13.361 trening sekvenci i 3.270 validacionih sekvenci, dužine 40 ciklusa. Postupak podjele po identifikatoru motora, zajedno s funkcijom za generisanje sekvenci, dat je u prilogima 7.1 i 7.2. Važno je napomenuti da validacioni RMSE iz analiza osjetljivosti nije direktno uporediv s testnim RMSE-om iz Poglavlja 6. Dok validacioni skup evaluiira model na svim vremenskim sekvencama tokom cjelokupnog radnog vijeka motora, testni skup mjeri performanse isključivo na završnom dostupnom prozoru za svaki od testnih motora čiji je rad prekinut prije otkaza.

Dužina ulaznog prozora od 30 ciklusa često se koristi kao standardna vrijednost za CMAPSS u literaturi [2, 12], međutim analiza osjetljivosti hiperparametara provedena u ovom radu ukazuje da veća vrijednost, $W = 40$ ciklusa, postiže bolji kompromis između tačnosti predikcije i pokrivenosti test skupa za implementiranu arhitekturu, te je stoga usvojena kao finalna vrijednost. Iza ovog odabira stoje dva suprotstavljena zahtjeva koja direktno proizlaze iz strukture podataka o degradaciji. S jedne strane, prozor mora biti dovoljno dugačak da LSTM može detektirati trendove degradacije: kratkoročne fluktuacije senzorskih signala uzrokovane šumom mjerenja maskiraju stvarni trend, pa je potrebno nekoliko desetaka ciklusa da bi se trend jasno izdvojio iz šuma. S druge strane, prozor ne smije biti previše dugačak: u ranoj fazi životnog vijeka motora senzorski signali su praktično stacionarni i ne nose prediktivnu informaciju, pa

uključivanje previše "zdravih" ciklusa razrjeđuje korisni signal i otežava učenje. Odabir vrijednosti W zasniva se na analizi osjetljivosti provedenoj na validacionom skupu, uz tri nezavisna slučajna sjemena po vrijednosti. Kako bi poređenje između različitih W bilo metodološki korektno, analiza je ograničena isključivo na motore koji imaju dovoljno ciklusa za najveću testiranu vrijednost prozora ($W = 60$); na taj način svi kandidati ocjenjuju se na identičnom podskupu motora, čime se izbjegava da prividno poboljšanje RMSE-a pri većim W vrijednostima proistekne iz promjene sastava skupa (isključivanja motora s kraćim životnim vijekom) umjesto iz stvarnog efekta dužine prozora. Tabela 5.2 prikazuje dobijene vrijednosti RMSE-a na ovako definiranom validacionom podskupu, te udio motora iz originalnog test skupa koji imaju dovoljno ciklusa za svaku vrijednost W .

W	RMSE (val)	Motora u testu s $\geq W$ ciklusa
15	15.14 ± 0.21	100/100
20	14.07 ± 0.22	100/100
25	13.02 ± 0.40	100/100
30	12.20 ± 0.29	100/100
40	10.79 ± 0.20	96/100
50	11.02 ± 0.26	93/100
60	10.45 ± 0.07	88/100

Tabela 5.2: Osjetljivost RMSE-a na dužinu ulaznog prozora W , uz udio test motora s dovoljno ciklusa za svaku vrijednost.

RMSE opada s povećanjem W sve do $W = 40$ (10.79), nakon čega blago raste pri $W = 50$ (11.02) prije nego što ponovo padne pri $W = 60$ (10.45); ovo posljednje poboljšanje, međutim, dolazi uz gubitak pokrivenosti test skupa na svega 88/100 motora. Vrijednost $W = 40$ odabrana je kao kompromis: nudi znatno bolji RMSE u odnosu na $W = 30$, dok istovremeno zadržava visok udio pokrivenosti test skupa (96/100 motora).

Preostala četiri motora, s manje od 40 raspoloživih ciklusa u testnom skupu, isključena su iz testnog skupa. Ovakvo filtriranje predstavlja konzervativniji izbor u odnosu na alternativne pristupe poput dopunjavanja nulama (*zero padding*) ili replikacije prvog dostupnog očitavanja unatrag do pune dužine prozora. Oba alternativna pristupa uvela bi vještačke, fizički nerealistične vrijednosti senzora na početku sekvence: vrijednost nula nakon MinMax normalizacije ne predstavlja "odsustvo signala" već konkretnu, validnu vrijednost unutar opsega mjerenja pojedinog senzora, pa bi njeno umjetno uvođenje moglo stvoriti lažni obrazac degradacije koji LSTM sloj pogrešno protumači kao stvaran trend. Replikacija prvog očitavanja izbjegava taj problem skoka u vrijednosti, ali uvodi drugačiji artefakt, vještački produžuje period prividne stagnacije stanja motora, čime bi se sistematski iskrivile upravo predikcije za motore s najkraćim dostupnim životnim vijekom, odnosno za slučajeve koji su i inače najizazovniji za procjenu RUL-a.

Važno je napomenuti i kakvu vrstu motora ovo isključivanje pogađa. Kraći dostupni niz u testnom skupu CMAPSS FD001 ne znači nužno da je motor ukupno kraćeg životnog vijeka već reflektuje činjenicu da je njegova trajektorija u testnom skupu presječena ranije u odnosu na trenutak kvara, čime je dostupno manje ciklusa historije prije nego što model treba predviđeti preostali vijek. Ovo znači da isključena četiri motora predstavljaju upravo one slučajeve u kojima model raspolaže najmanjom količinom historijskih podataka u trenutku predikcije, scenarij koji je u praktičnoj primjeni prediktivnog održavanja poseban izazov, jer se rana dijagnoza zasniva na ograničenom broju opažanja. Njihovo isključivanje iz testnog skupa stoga nije neutralno u odnosu na težinu evaluacije: rezultati prikazani u Poglavlju 6 odnose se na podskup motora s dovoljno dugom raspoloživom historijom da model može iskoristiti puni ulazni prozor,

dok se izvedba na motorima s vrlo kratkom dostupnom historijom eksplicitno ne evaluira. Ovo predstavlja ograničenje rada koje je vrijedno istaknuti: u realnoj primjeni sistem bi morao imati strategiju i za motore s manje od W dostupnih ciklusa, bilo kroz dinamičku dužinu prozora, bilo kroz zaseban model treniran na kraćim sekvencama.

S obzirom na navedeno, odluka o isključivanju umjesto umjetnog dopunjavanja predstavlja svjestan kompromis: žrtvuje se potpuna pokrivenost testnog skupa (4% motora) radi očuvanja integriteta ulaznih podataka za preostalih 96% motora, čime se izbjegava rizik da artefakti dopunjavanja sistematski naruše procjenu tačnosti i kalibracije za sve modele podjednako. Finalni testni skup nakon filtriranja broji 96 motora. Za test skup formira se samo jedna sekvenca po motoru, ona koja završava s posljednjim dostupnim ciklusom.

6. Eksperimentalna evaluacija

Ovo poglavlje prezentira rezultate eksperimentalne evaluacije četiri modela implementirana u ovom radu: determinističkog baseline LSTM modela i triju metoda kvantifikacije nesigurnosti: Monte Carlo Dropout, Deep Ensemble i hibridne Bayesovske neuronske mreže. Svi modeli treniraju se na identičnom trening skupu CMAPSS FD001 i evaluiraju na istom testnom skupu, čime se osigurava direktna usporedivost rezultata. Eksperimentalna postavka opisana je u nastavku, a zatim slijede rezultati svakog modela ponaosob, proširene analize i sveobuhvatna usporedna diskusija u zaključnom dijelu poglavlja.

6.1 Eksperimentalna postavka

Odabir hiperparametara sistematski je provjeren jednodimenzionalnom (OFAT) analizom osjetljivosti na validacionom skupu. Rezultati i obrazloženje odabranih vrijednosti W i p dati su uz opis odgovarajuće metode odnosno komponente u Poglavljima 4 i 5.2; broj epoha, kao parametar zajednički svim modelima, obrađen je u nastavku ove sekcije. OFAT pristup ne hvata interakcije između hiperparametara niti garantuje globalni optimum; korišten je zbog obima rada, umjesto pune multi-dimenzionalne optimizacije.

Svi modeli dijele zajedničku LSTM arhitekturu koja se sastoji od dva rekurentna sloja s 64 i 32 jedinice, dva gusta sloja i dropout regularizacijom između njih. Ova arhitektura definirana je funkcijom prikazanom u Programu 7.3. Arhitektura je detaljno opisana u Poglavlju 4; ovdje su navedeni isključivo parametri relevantni za reproducibilnost eksperimenata.

Svi eksperimenti izvedeni su u Python okruženju unutar Google Colab platforme, korištenjem TensorFlow/Keras biblioteke (v2.20.0) za implementaciju LSTM arhitekture i svih UQ metoda, uključujući i vlastitu implementaciju varijacionog DenseVariational sloja s reparametrizacijskim trikom, implementiranog direktno u TensorFlow-u, dok su scikit-learn (v1.6.1), SciPy (v1.16.3), NumPy (v2.0.2) i pandas (v2.2.3) korišteni za pretprocesiranje podataka, standardne metrike i statističke analize.

Modeli su trenirani kroz 50 epoha s batch veličinom 64 i Adam optimizatorom s početnom stopom učenja 10^{-3} . Ulazne sekvence su dužine $W = 40$ ciklusa, a skup značajki obuhvata 17 varijabli identificiranih u EDA analizi opisanoj u Poglavlju 5.2. Tokom inferencije, za svaki motor iz testnog skupa provodi se 100 stohastičkih prolaza za MC Dropout i hibridni BNN, dok Deep Ensemble agregira predikcije pet nezavisno treniranih modela pri čemu svaki model daje 20 stohastičkih prolaza, čime ukupan broj uzoraka po ulazu ostaje jednak za sve metode i direktna usporedivost procijenjenih intervala nesigurnosti je osigurana.

Odabir broja epoha zasniva se na dvije komplementarne provjere. Prva je kriva konvergencije treninga uz EarlyStopping mehanizam (*patience* = 10): trening je zaustavljen nakon 27 epoha, pri čemu je najniža vrijednost validacionog gubitka zabilježena na 17. epohi, što pokazuje da model konvergira znatno prije gornje granice od 50 epoha. Druga provjera je analiza osjetljivosti bez EarlyStopping mehanizma, provedena na validacionom skupu uz tri nezavisna

slučajna sjemena za svaku vrijednost, prikazana u Tabeli 6.1.

Broj epoha	RMSE
20	12.99 ± 0.48
50	12.69 ± 0.17
80	13.54 ± 0.78

Tabela 6.1: Osjetljivost RMSE-a na broj epoha treninga, bez *EarlyStopping* mehanizma.

Rezultati pokazuju da 50 epoha postiže i najniži i najstabilniji RMSE (12.69 ± 0.17) od svih testiranih vrijednosti, dok 80 epoha pokazuje pogoršanje tačnosti uz znatno veću varijansu (13.54 ± 0.78), što ukazuje na *overfitting* pri produženom treningu bez regularizacijskog mehanizma. Na osnovu ove dvije provjere, 50 epoha usvojeno je kao gornja granica treninga, uz *EarlyStopping* (*patience* = 10, *restore_best_weights*) kao dodatnu sigurnosnu mjeru koja osigurava korištenje težina iz optimalne epohe bez obzira na stvarni broj izvedenih epoha. Testni skup, nakon isključivanja motora s nedovoljnim brojem ciklusa za $W = 40$, broji 96 motora.

Evaluacija obuhvata dvije komplementarne dimenzije: tačnost tačkaste predikcije, mjerena RMSE i MAE metrikama, te kvalitet kvantifikacije nesigurnosti, mjeren skupom metrika specifičnih za probabilističke modele: pokrivenost prediktivnih intervala (CP), srednja širina intervala (MIW), negativna log-vjerodostojnost (NLL) i srednja apsolutna kalibraciona greška (MACE), čije su definicije date u Poglavlju 3.

6.2 Referentno pokretanje za eksperimentalnu evaluaciju

Rezultati probabilističkih modela mogu varirati između nezavisnih pokretanja zbog različite inicijalizacije parametara i stohastičkih elemenata procesa treniranja. Kako bi se izbjeglo donošenje zaključaka na osnovu jednog, potencijalno nereprezentativnog pokretanja, provedeno je deset nezavisnih pokretanja cijelog eksperimenta, pri čemu je za svako pokretanje korišteno različito sjeme. Za svaku metriku i svaki model izračunate su srednja vrijednost i standardna devijacija na osnovu rezultata svih deset pokretanja. U Tabeli 6.2 rezultati su prikazani u obliku $\text{mean} \pm \text{std}$.

Tabela 6.2: Stabilnost modela kroz 10 nezavisnih pokretanja.

Model	RMSE	MAE	Coverage	NLL	MIW	MACE
Baseline LSTM	14.42 ± 0.28	10.24 ± 0.27	-	-	-	-
MC Dropout	14.35 ± 0.18	10.33 ± 0.21	0.80 ± 0.03	4.34 ± 0.20	31.12 ± 1.47	0.14 ± 0.03
Deep Ensemble	14.17 ± 0.11	9.99 ± 0.10	0.82 ± 0.02	4.16 ± 0.14	32.26 ± 1.53	0.09 ± 0.02
Hibridni BNN	14.46 ± 0.23	10.35 ± 0.22	0.85 ± 0.04	4.19 ± 0.29	37.20 ± 3.61	0.09 ± 0.03

Rezultati u Tabeli 6.2 pokazuju relativno stabilno ponašanje svih modela kroz 10 nezavisnih pokretanja. Standardne devijacije RMSE-a kreću se u rasponu od 0.11 do 0.28 ciklusa, pri čemu Deep Ensemble pokazuje najmanju varijabilnost (± 0.11), dok Baseline LSTM ima najveću (± 0.28). Kod probabilističkih modela, Hibridni BNN ostvaruje najvišu prosječnu pokrivenost intervala (0.85 ± 0.04), zatim Deep Ensemble (0.82 ± 0.02) i MC Dropout (0.80 ± 0.03). Standardne devijacije pokrivenosti relativno su male, što ukazuje na stabilnost ovog pokazatelja kroz različita pokretanja.

Kriterijum odabira reprezentativnog pokretanja

Budući da je pokrivenost prediktivnih intervala (*coverage*) centralna metrika za diskusiju kalibracije u ovom radu, reprezentativno pokretanje odabrano je na osnovu bliskosti prosječnom *coverage*-u, a ne na osnovu RMSE-a. Za svako od deset pokretanja izračunata je Euklidska udaljenost *coverage* vrijednosti sva tri UQ modela od desetostrukog prosjeka:

$$d_{\text{run}} = \sqrt{\sum_{m \in \{\text{MCD}, \text{DE}, \text{BNN}\}} (\text{CP}_{m,\text{run}} - \overline{\text{CP}}_m)^2} \quad (6.1)$$

Tabela 6.3: Odstupanje *coverage*-a svakog pokretanja od prosjeka kroz 10 nezavisnih pokretanja.

Run	Seed	MCD Coverage	DE Coverage	BNN Coverage	Udaljenost d
1	0	0.8542	0.8333	0.8750	0.0574
2	100	0.7708	0.8333	0.8438	0.0367
3	200	0.7813	0.8542	0.9167	0.0760
4	300	0.8021	0.8021	0.8854	0.0364
5	400	0.8229	0.8125	0.8750	0.0302
6	500	0.7500	0.7813	0.8125	0.0767
7	600	0.8021	0.8542	0.8750	0.0416
8	700	0.8021	0.7917	0.7813	0.0768
9	800	0.8542	0.8229	0.8854	0.0605
10	900	0.7917	0.8021	0.7813	0.0747

Pokretanje 5 (*seed* = 400) pokazuje najmanju ukupnu udaljenost od prosjeka ($d = 0.0302$) i stoga je odabrano kao reprezentativno za sve detaljne analize. Vrijedno je napomenuti da unutar pokretanja 5 relativni poredak modela po *coverage*-u blago odstupa od poretka baziranog na desetostrukom prosjeku: MC Dropout neznatno nadmašuje Deep Ensemble, dok je u prosjeku kroz svih deset pokretanja odnos obrnut. Ova razlika je posljedica prirodne varijabilnosti pojedinačnih pokretanja i činjenice da kriterijum d_{run} minimizira zajedničko odstupanje sva tri modela istovremeno, a ne garantuje očuvanje relativnog poretka svakog modela pojedinačno. Budući da se standardne devijacije *coverage*-a za MCD i DE djelomično preklapaju, ovakva lokalna inverzija poretka je statistički očekivana i ne dovodi u pitanje opšte zaključke izvedene iz agregiranih rezultata kroz svih deset pokretanja.

U preostalim sekcijama ovog poglavlja, glavne agregatne metrike tačnosti i kalibracije (RMSE, MAE, pokrivenost prediktivnih intervala i NLL) izražavaju se kao $\text{mean} \pm \text{std}$ kroz deset nezavisnih pokretanja (Tabela 6.2), čime se zaključci o odnosu metoda zasnivaju na dokazanoj robusnosti kroz više pokretanja, a ne na jednom uzorku. Metrike i vizualizacije koje zahtijevaju kompletan skup predikcija po pojedinačnom motoru, kao što su *scatter* i *uncertainty profile* grafici, dekompozicija nesigurnosti, dijagram kalibracije te *conformal* i *bootstrap* analize, nisu agregirane kroz svih deset pokretanja te se stoga prikazuju isključivo na reprezentativnom pokretanju odabranom u ovoj sekciji.


6.3 Eksperimentalni rezultati

U nastavku su prikazani rezultati svakog od četiri implementirana modela. Deterministički baseline LSTM služi kao referentna tačka za evaluaciju prediktivne tačnosti, dok preostale tri metode uz tačkastu predikciju pružaju i kvantificiranu mjeru nesigurnosti. Budući da sve četiri metode dijele identičnu LSTM arhitekturu, razlike u rezultatima mogu se pripisati isključivo mehanizmu kvantifikacije nesigurnosti, a ne arhitekturnim odlukama.

6.3.1 Deterministički baseline model

Deterministički LSTM model treniran je bez ikakvog mehanizma kvantifikacije nesigurnosti i služi isključivo kao referentna tačka za evaluaciju prediktivne tačnosti UQ metoda. Njegova uloga u eksperimentalnom okviru je dvojaka: s jedne strane, omogućava izolaciju doprinosa UQ mehanizma od arhitektonskih razlika, budući da sve četiri metode dijele identičnu LSTM arhitekturu, razlike u rezultatima mogu se pripisati isključivo načinu kvantifikacije nesigurnosti, a ne arhitekturi. S druge strane, baseline RMSE i MAE vrijednosti predstavljaju prag koji UQ metode moraju dostići ili nadmašiti kako bi se potvrdilo da uvođenje probabilističkog tretmana ne narušava prediktivnu preciznost.

Model postiže $RMSE = 14.42 \pm 0.28$ i $MAE = 10.24 \pm 0.27$ ciklusa na testnom skupu CMAPSS FD001 (mean $\pm$ std kroz deset nezavisnih pokretanja). Slika 6.1, generirana na reprezentativnom pokretanju, stavlja ove aggregate u kontekst: većina tačaka grupira se blizu dijagonale idealne predikcije, što ukazuje da model ispravno aproksimira trend degradacije kroz cijeli raspon RUL vrijednosti. Vidljiva su, međutim, i sistematska odstupanja u pojedinim regijama RUL raspona, gdje senzorski signali pokazuju veću varijabilnost između motora, što je upravo tip nesigurnosti koji deterministički model ne može detektirati niti komunicirati korisniku.



Slika 6.1: Scatter plot predikcija determinističkog baseline modela nasuprot stvarnih RUL vrijednosti. Boja svake tačke kodira apsolutnu grešku predikcije: zeleno označava malu grešku, a crveno veliku. Dijagonala predstavlja idealnu predikciju.


Premda tačnost ovog modela predstavlja solidnu polaznu tačku, njegova fundamentalna slabost leži u tome što producira isključivo tačkastu predikciju, jednu skalarnu vrijednost bez

ikakve mjere pouzdanosti. Inženjer koji od ovakvog modela dobije predikciju da motor ima 20 preostalih ciklusa nema osnovu za procjenu koliko se na tu informaciju može osloniti: ne zna je li model siguran u tu procjenu ili nagađa. Upravo ovo ograničenje motivira implementaciju triju UQ metoda koje slijede.

6.3.2 Monte Carlo Dropout

Monte Carlo Dropout primjenjuje istu LSTM arhitekturu kao baseline model, uz ključnu razliku da dropout slojevi ostaju aktivni i tokom faze inferencije. Pokretanjem 100 stohastičkih prolaza kroz model za svaki motor iz testnog skupa dobiva se distribucija predikcija čija srednja vrijednost predstavlja konačni RUL, a standardna devijacija kvantificira ukupnu nesigurnost, kombinaciju epistemičke i aleatoričke komponente bez eksplicitnog razdvajanja.

Model postiže $RMSE = 14.35 \pm 0.18$ i $MAE = 10.33 \pm 0.21$, čime se tačnost zadržava na razini baseline modela. Srednja širina prediktivnih intervala iznosi 31.12 ± 1.47 ciklusa. Slika 6.2, generirana na reprezentativnom pokretanju, prikazuje predikcije i intervale nesigurnosti za sve motore u testnom skupu sortirane po stvarnom RUL-u.



Slika 6.2: MC Dropout predikcije RUL-a s 95% intervalima nesigurnosti za sve motore u testnom skupu, sortirani po stvarnom RUL-u. Plava linija predstavlja predviđenu srednju vrijednost, a osjenčano područje interval $\hat{\mu} \pm 2\hat{\sigma}$.


Vizualizacija otkriva karakteristično ponašanje: intervali nesigurnosti su širi za motore s visokim RUL-om, to jest u ranoj fazi životnog vijeka gdje trening skup ima manje primjera koji odgovaraju tom stanju degradacije i postupno se sužavaju kako se motor približava kvaru. Ovaj obrazac je konzistentan s očekivanjem da epistemička nesigurnost opada kako model nailazi na stanja slična onima viđenim tokom treninga.

Po metrikama kalibracije, pokrivenost prediktivnih intervala na 95% nominalnom nivou iznosi 0.80 ± 0.03 , što je ispod ciljanih 0.95 i ukazuje na blagu samopouzdanost, model je nešto sigurniji u svoje predikcije nego što empirijska pokrivenost opravdava. $NLL = 4.34 \pm 0.20$ potvrđuje da kalibracija postoji ali nije idealna. $MACE = 0.14 \pm 0.03$, dodatno potvrđuje da je MC Dropout najslabije kalibrirana od sve tri implementirane UQ metode. Ključno ograničenje metode, koje će biti detaljnije razmotreno u odjeljku 6.4.1, jest da standardna devijacija iz MC Dropout uzoraka ne razdvaja epistemičku od aleatoričke nesigurnosti.

6.3.3 Deep Ensemble

Deep Ensemble trenira pet nezavisnih instanci iste arhitekture s različitim inicijalizacijama parametara. Raznolikost predikcija između članova ansambla nastaje kao posljedica nekonveksnosti optimizacijskog prostora, različite inicijalizacije pronalaze funkcionalno različita rješenja, čime se postiže robusnija procjena nesigurnosti nego uzorkovanjem iz jednog modela [10]. Tokom inferencije svaki od pet modela daje 20 stohastičkih prolaza, što daje ukupno 100 uzoraka po ulazu.

Model postiže $RMSE = 14.17 \pm 0.11$ i $MAE = 9.99 \pm 0.10$, čime se tačnost ne samo zadržava na razini baseline i MC Dropout modela, nego se i poboljšava. Srednja širina prediktivnih intervala iznosi 32.26 ± 1.53 ciklusa, što je nešto šire nego kod MC Dropouta, što ne odražava nužno veću nesigurnost već raznolikost između funkcionalno različitih modela u ansamblu. Slika 6.3, generirana na reprezentativnom pokretanju, prikazuje predikcije i intervale nesigurnosti.




Slika 6.3: Deep Ensemble predikcije RUL-a s 95% intervalima nesigurnosti. Zelena linija predstavlja predviđenu srednju vrijednost, a osjenčano područje interval $\hat{\mu} \pm 2\hat{\sigma}$.

Po metrikama kalibracije, Deep Ensemble postiže pokrivenost od 0.82 ± 0.02 i $NLL = 4.16 \pm 0.14$, uz iznimno nisku varijansu koja ukazuje na konzistentnu kalibraciju kroz pokretanja. MACE od 0.09 ± 0.02 predstavlja solidnu kalibraciju Deep Ensemble modela kroz 10 nezavisnih pokretanja. To je i dalje u skladu s teorijskim prednostima ansambla: funkcionalna raznolikost članova pruža bolju pokrivenost distribucijskog prostora od stohastičkih uzoraka jednog modela, čime se dobiva pouzdanija procjena ukupne nesigurnosti [10]. Ova prednost dolazi, međutim, po jasnoj cijeni: treniranje pet modela zahtijeva otprilike petostruko više računskog vremena u odnosu na jedan model, što u primjenama s velikim arhitekturama može biti ograničavajući faktor. Varijansa ansambla kombinira dva izvora nesigurnosti bez eksplicitnog razdvajanja: neslaganje između pet nezavisno treniranih modela i dropout uzorkovanje unutar svakog člana. Ova hijerarhijska mješavina izvora, razlog je zbog kojeg heuristička dekompozicija primijenjena na MC Dropout i hibridni BNN nije primjenjiva na Deep Ensemble.

6.3.4 Hibridna Bayesovska neuronska mreža

Hibridna BNN arhitektura zadržava deterministički tretman LSTM slojeva, dok varijacionu inferenciju primjenjuje isključivo na gustim izlaznim slojevima putem prilagođenog DenseVariational sloja koji koristi reparametrizacijski trik [24]. Ovakav hibridni pristup


svjesni je kompromis između teorijske rigoroznosti punog BNN-a i računskih ograničenja. Potpuno varijacioni LSTM slojevi zahtijevali bi distribuiranje nad znatno većim brojem parametara uz minimalni praktični dobitak na setu podataka ove veličine [14].



Slika 6.4: Hibridni BNN predikcije RUL-a s 95% intervalima nesigurnosti. Crvena linija predstavlja predviđenu srednju vrijednost, a osjenčano područje interval $\hat{\mu} \pm 2\hat{\sigma}$.

Model postiže $RMSE = 14.46 \pm 0.23$ i $MAE = 10.35 \pm 0.22$, sa srednjom širinom prediktivnih intervala od 37.20 ciklusa ± 3.61 , najširim intervalima od sve tri metode kvantifikacije nesigurnosti. Po metrikama kalibracije, pokrivenost iznosi 0.85 ± 0.04 , najviši od sve tri metode, i $NLL = 4.19 \pm 0.29$. MACE od 0.09 ± 0.03 predstavlja statistički gotovo identičnu kalibraciju Deep Ensemble modelu, razlika između dva modela je zanemarljiva i u potpunosti unutar jedne standardne devijacije, pa se ne može govoriti o jasnoj prednosti jednog modela nad drugim po ovoj metrici. Širi intervali u kombinaciji s visokom pokrivenošću ukazuju da varijaciona inferencija ne pokazuje sklonost prekomjernoj pouzdanosti, već naprotiv postiže pokrivenost najbližu nominalnom cilju od 95% uz najnižu kalibracionu grešku.

Krivulja konvergencije treninga (Slika 6.5) otkriva karakteristično dvofazno učenje: u prvoj fazi LSTM slojevi ekstrahuju sekvencijalne obrasce degradacije, a u drugoj fazi varijacioni Dense slojevi refiniraju probabilistički izlaz. Zajedno s MC Dropout metodom, hibridni BNN omogućava aproksimativnu dekompoziciju nesigurnosti na epistemičku i aleatoričku komponentu. Ova dekompozicija razrađena je u odjeljku 6.4.1.



Slika 6.5: Krivulja konvergencije hibridnog BNN modela.

6.4 Usporedne analize i diskusija


6.4.1 Dekompozicija nesigurnosti

Razlikovanje epistemičke i aleatoričke nesigurnosti nije samo teorijski relevantno, ima direktne praktične implikacije za odluke o održavanju opisane u Poglavlju 3. Dekompozicija se provodi za MC Dropout i hibridni BNN, jer oba modela nesigurnost generiraju kroz stohastičko uzorkovanje što omogućava primjenu aproksimativne metode dekompozicije. Deep Ensemble je izostavljen iz ove analize jer njegova varijansa ne proizlazi iz jednog homogenog izvora uzorkovanja poput MC Dropout-a i hibridnog BNN-a. Primjena iste heuristike na takvu mješavinu izvora ne bi imala jasno konceptualno značenje, budući da bi procijenjena osnovna komponenta aleatoričke nesigurnosti predstavljala nerazdvojivu smjesu neusklađenosti modela i unutrašnjeg uzorkovanja, umjesto čiste procjene ireducibilnog šuma.

Precizna dekompozicija ukupne nesigurnosti na epistemičku i aleatoričku komponentu zahtijeva arhitekturu s dvije zasebne izlazne glave koje direktno uče heteroscedastičnu aleatoričku varijansu [6]. Budući da takva arhitektura nije implementirana u ovom radu, koristi se heuristička aproksimacija zasnovana na intuiciji da aleatorička nesigurnost predstavlja ireducibilni donji prag ukupne nesigurnosti [6, 7]: aleatorička komponenta aproksimira se kao 10. percentil ukupne standardne devijacije unutar lokalnih binova u prostoru RUL vrijednosti. Ova vrijednost odgovara minimalnoj opažanoj nesigurnosti u svakom regionu, tj. dijelu nesigurnosti koji ostaje čak i kada je model relativno siguran u svoju predikciju. Epistemička komponenta dobiva se kao razlika između ukupne standardne devijacije i aleatoričke aproksimacije:

$$\hat{\sigma}_{ep}(\mathbf{x}) = \max(\hat{\sigma}_{total}(\mathbf{x}) - \hat{\sigma}_{al}(\mathbf{x}), 0) \quad (6.2)$$

gdje je $\hat{\sigma}_{al}(\mathbf{x})$ aproksimirana aleatorička standardna devijacija dobivena kao 10. percentil ukupne standardne devijacije unutar odgovarajućeg RUL bina. Ova heuristika implementirana je u Programu 7.8. Za hibridni BNN, ista metodologija primjenjuje se na distribuciju predikcija dobivenih stohastičkim uzorkovanjem varijacionih izlaznih slojeva, pri čemu varijacioni tretman gustih slojeva dodatno doprinosi epistemičkoj komponenti kroz širinu naučenih distribucija težina.




Slika 6.6: Aproksimativna dekompozicija nesigurnosti na aleatoričku i epistemičku komponentu za MC Dropout (lijevo) i hibridni BNN (desno). Motori su sortirani po stvarnom RUL-u.

Rezultati prikazani na Slici 6.6 pokazuju da kod oba modela dominira aleatorička nesigurnost. Kod MC Dropouta prosječna aleatorička komponenta iznosi 6.30 ciklusa, a epistemička 1.47 ciklusa (19.10% ukupne procijenjene standardne devijacije). Kod hibridnog BNN-a te

vrijednosti su 8.34 i 1.64 ciklusa (16.64% ukupne procijenjene standardne devijacije). Dominacija aleatoričke komponente konzistentna je s fizičkom prirodom procesa degradacije mlaznih motora: šum senzora, varijabilnost u materijalima komponenti i stohastičnost samog procesa trošenja uvode ireducibilnu nesigurnost koja ne može biti eliminirana poboljšanjem modela [5]. Relativno nizak udio epistemičke nesigurnosti, s druge strane, ukazuje da su oba modela uspješno ekstrahovala dominantne obrasce degradacije dostupne u trening skupu. Hibridni BNN pokazuje nešto veći apsolutni iznos obje komponente u odnosu na MC Dropout, dok je relativni udio epistemičke komponente kod obje metode uporediv (16–19% ukupne procijenjene standardne devijacije), s neznatno nižim relativnim udjelom kod hibridnog BNN-a usljed proporcionalno veće aleatoričke komponente.

6.4.2 Kalibracija prediktivnih intervala

Dijagram kalibracije prikazuje opaženu pokrivenost (*coverage*) nasuprot nominalnom nivou pouzdanosti za raspon od 5% do 99%. Savršeno kalibriran model prati dijagonalu, svaki nominalni nivo pouzdanosti p odgovara empirijskoj frekvenciji pokrivenosti $\hat{p} = p$. Krivulja iznad dijagonale ukazuje na precjenjivanje nesigurnosti (model je konzervativan, intervali su preširoki), a krivulja ispod dijagonale na potcjenjivanje (intervali su pretjesni).



Slika 6.7: Dijagram pouzdanosti za sve tri UQ metode. Isprekidana dijagonala predstavlja idealnu kalibraciju. Krivulje iznad dijagonale ukazuju na precjenjivanje nesigurnosti, a ispod na potcjenjivanje.

Dijagram prikazan na Slici 6.7 vizualno potvrđuje zaključke dobivene MACE metrikama. Sve tri krivulje leže ispod ili neposredno uz dijagonalu već od najnižih nominalnih nivoa, bez

izražene faze precjenjivanja nesigurnosti. Odstupanje od idealne kalibracije postaje izraženije tek od približno 0.25–0.3 nadalje i nastavlja rasti kroz preostali dio raspona, što ukazuje na sistematsko potcjenjivanje nesigurnosti pri srednjim i visokim nivoima pouzdanosti, upravo u regiji najrelevantnijoj za praktičnu primjenu. Metode se razlikuju po stepenu ovog potcjenjivanja: Hibridni BNN ($\text{MACE} = 0.09 \pm 0.03$) i Deep Ensemble ($\text{MACE} = 0.09 \pm 0.02$) postižu praktično identičnu kalibraciju, krivulja Hibridnog BNN-a je nešto bliža dijagonali kroz srednji i visoki raspon, no razlika u MACE vrijednostima je zanemarljiva i u potpunosti unutar jedne standardne devijacije. MC Dropout ($\text{MACE} = 0.14 \pm 0.03$) je jasno najlošije kalibrirana metoda, s krivuljom koja se kroz gotovo cijeli srednji i visoki raspon najviše udaljava od dijagonale. Ovaj rang metoda: MC Dropout kao najlošiji, uz Deep Ensemble i Hibridni BNN međusobno statistički izjednačene, slaže se s rangom pokrivenosti pri nominalnom nivou od 95% prikazanim u Tabeli 6.2.

6.4.3 Teorijska garancija pokrivenosti

Prethodne analize pokazale su da niti jedna od implementiranih UQ metoda ne dostiže ciljani coverage od 0.95 bez *post-hoc* kalibracije: Deep Ensemble postiže 0.82 ± 0.02 , MC Dropout 0.80 ± 0.03 , a hibridni BNN 0.85 ± 0.04 . Konformna predikcija je *post-hoc* kalibracijska tehnika koja rješava ovaj problem bez ponovnog treniranja modela [27]. Za razliku od prethodnih metoda čija pokrivenost je empirijska, konformna predikcija pruža teorijsku garanciju pokrivenosti, uz pretpostavku da kalibracijski i testni skup potječu iz iste distribucije, kroz konstrukciju intervala oblika:

$$\hat{C}(x) = [\hat{\mu}(x) - \hat{q}, \hat{\mu}(x) + \hat{q}] \quad (6.3)$$

gdje je $\hat{q} (1 - \alpha)(1 + 1/n_{\text{cal}})$ -ti kvantil skupa ocjena neusklađenosti $\{|y_i - \hat{\mu}(x_i)|\}_{i=1}^{n_{\text{cal}}}$ izračunatih na kalibracijskom skupu od n_{cal} primjera [28].

Implementacija split conformal kalibracije data je u prilogu 7.10. U eksperimentu je 20% testnog skupa izdvojeno kao kalibracijski skup, što zbog filtriranja motora s nedovoljnim brojem ciklusa (96 od originalnih 100 motora u testnom skupu) daje $n_{\text{cal}} = 19$ motora, dok se ostatak (77 motora) koristi za finalnu evaluaciju, na reprezentativnom pokretanju. Pri ovako maloj veličini kalibracionog skupa i ciljanom nivou pouzdanosti od 95%, potrebni kvantil $(1 - \alpha)(1 + 1/n_{\text{cal}}) = 0.95 \times (20/19) \approx 1.0$ odgovara praktično maksimalnoj (najgore slučaju) vrijednosti neusklađenosti u kalibracionom skupu. Teorijska garancija konformne predikcije je stoga u ovom režimu na samoj granici primjenjivosti i izuzetno je osjetljiva na pojedinačne motore u kalibracionom skupu. Zamjena ili izostavljanje samo jednog motora mogla bi značajno promijeniti dobiveni $\hat{q}$.

Dobiveni $\hat{q}$ kvantili su: MC Dropout 31.87, Deep Ensemble 27.79 i hibridni BNN 34.22 ciklusa. Deep Ensemble ovdje pokazuje najmanji $\hat{q}$ među sve tri metode, dok hibridni BNN ostaje najveći (za oko 2.4–6.4 ciklusa u odnosu na preostale dvije metode), što je konzistentno sa širim originalnim intervalima nesigurnosti dobivenim za ovaj model.

Rezultati u Tabeli 6.4 pokazuju da konformna predikcija uspješno približava pokrivenost nominalnom cilju od 0.95 kod sve tri metode, iako ne identično: MC Dropout dostiže 0.948, hibridni BNN 0.961, dok Deep Ensemble ostaje nešto ispod cilja s 0.922. Cijena ove korekcije je proširenje intervala: MC Dropout s 30.12 na 63.75 ciklusa, Deep Ensemble s 31.71 na 55.57, a hibridni BNN s 38.52 na 68.43. Hibridni BNN zadržava primjetno šire kalibrirane intervale u odnosu na Deep Ensemble, koji sada nudi najuže i time najinformativnije kalibrirane intervale od sve tri metode. Ovo opažanje ima važnu praktičnu implikaciju: iako konformna predikcija

Tabela 6.4: Usporedba originalnih i conformal prediction intervala za sve tri UQ metode (izračunato na 77 motora testnog skupa nakon izdvajanja kalibracionog skupa).

Model	Coverage (original)	Coverage (CP)	Width (original)	Width (CP)
MC Dropout	0.792	0.948	30.12	63.75
Deep Ensemble	0.818	0.922	31.71	55.57
Hibridni BNN	0.831	0.961	38.52	68.43

uspješno garantuje pokrivenost blizu nominalnog cilja za sve tri metode, ne izjednačava nužno njihovu oštrinu (širinu intervala). Metoda s manje konzervativnom originalnom procjenom nesigurnosti (Deep Ensemble) zadržava i nakon kalibracije uže intervale, što ostaje relevantan kriterij pri izboru metode i nakon što je pitanje pokrivenosti riješeno. Treba, međutim, imati u vidu i prethodno navedeno ograničenje malog kalibracionog skupa pri tumačenju preciznosti ovih rezultata.

6.4.4 Sinteza rezultata

Rezultati tačnosti i kalibracije predstavljeni pojedinačno za svaki model u Sekcijama 6.3.1–6.3.4, te agregirani kroz deset nezavisnih pokretanja u Tabeli 6.2, objedinjuju se u ovoj sekciji radi cjelovite usporedbe.

Prva opservacija jest da su razlike u RMSE-u između sva četiri modela relativno male, pri čemu je hibridni BNN jedina UQ metoda koja ostvaruje neznatno veći prosječni RMSE od determinističkog baseline modela. Deep Ensemble i MC Dropout, s druge strane, u prosjeku postižu niži RMSE od baselinea. Ovo je vrijedan nalaz u cjelini: uvođenje probabilističkog tretmana ne narušava nužno prediktivnu tačnost, čime se dovodi u pitanje uobičajena pretpostavka da je kvantifikacija nesigurnosti nužno praćena gubitkom tačnosti.

Kako bi se procijenila statistička značajnost ovih razlika, provedena je bootstrap analiza. Bootstrap je neparametarska metoda statističkog zaključivanja koja procjenjuje distribuciju neke statistike (u ovom slučaju RMSE) ponovnim uzorkovanjem s ponavljanjem iz dostupnog skupa podataka [29]. Umjesto pretpostavki o distribuciji podataka, metoda empirijski konstruira distribuciju metrike kroz veliki broj iteracija: u svakoj iteraciji formira se novi uzorak iste veličine kao originalni testni skup (uz ponavljanje), izračuna se RMSE na tom uzorku, a na kraju se iz skupa svih dobivenih vrijednosti konstruira interval pouzdanosti. U ovom radu provedeno je 1000 iteracija na reprezentativnom pokretanju, uz fiksirano slučajno sjeme radi reproducibilnosti, a rezultati su prikazani u Tabeli 6.5.

Tabela 6.5: Bootstrap 95% intervali pouzdanosti za RMSE.

Model	RMSE	Donja granica	Gornja granica
Baseline LSTM	14.04	11.61	16.43
MC Dropout	14.25	11.78	16.75
Deep Ensemble	14.19	11.73	16.59
Hibridni BNN	14.20	11.63	16.50

Rezultati u Tabeli 6.5 pokazuju da su svi 95% intervali pouzdanosti široki i međusobno se u potpunosti preklapaju, što znači da razlike u tačnosti između metoda nisu statistički značajne. Sve četiri tačkaste RMSE vrijednosti leže duboko unutar preklapajućeg područja sva četiri inter-

vala, a raspon svakog pojedinačnog intervala znatno je širi od razlika između tačkastih procjena modela. Ova širina intervala nije iznenađujuća s obzirom na relativno mali testni skup: što je testni skup manji, bootstrap distribucija je šira i intervali pouzdanosti su manje precizni. Zaključak koji iz ovoga slijedi je konzervativan ali važan: na osnovu dostupnih podataka ne može se tvrditi da je ijedna od implementiranih UQ metoda statistički superiorna po dimenziji tačnosti predikcije, što dodatno potkrepljuje argument da se metode trebaju razlikovati i vrednovati primarno po dimenziji kalibracije nesigurnosti.

Vrijedi napomenuti da rangiranje modela u Tabeli 6.5 nije identično rangiranju iz Tabele 6.2: Baseline LSTM ovdje ostvaruje najniži RMSE, dok je u prosjeku kroz deset pokretanja treći od četiri modela, a MC Dropout, koji je u analizi stabilnosti drugi najbolji, ovdje ispada najlošiji. Ovo naizgled nije kontradikcija, već posljedica činjenice da su dvije analize rađene na različitim izvorima varijabilnosti: bootstrap ponovno uzorkuje testni skup jednog fiksnog, već istreniranog modela iz reprezentativnog pokretanja, dok analiza stabilnosti računa prosjek rezultata od deset nezavisno treniranih modela s različitim inicijalizacijama. Male razlike u tačnosti pojedinog reprezentativnog modela stoga ne moraju odražavati prosječno ponašanje metode kroz više treninga, što dodatno naglašava zašto se zaključci o tačnosti u ovom radu prvenstveno oslanjaju na agregirane rezultate iz Tabele 6.2, a bootstrap analiza služi samo kao provjera statističke značajnosti unutar jednog pokretanja.

Dimenzija kalibracije daje jasniju sliku razlika među metodama. Nijedna od triju metoda ne dostiže nominalni 95% nivo pokrivenosti, što znači da su svi modeli u određenoj mjeri precijenjene sigurnosti, nalaz konzistentan s opservacijama Basore et al. [8] na N-CMAPSS setu podataka. Detaljna analiza stepena i karaktera ovog odstupanja, uključujući dijagram pouzdanosti i konzistentan rang metoda po MACE, prezentirana je u Sekciji 6.4.2. Konformna kalibracija dodatno pokazuje da hibridni BNN, iako zadržava najšire intervale, ostaje konzervativniji (coverage $0.961 > 0.95$), dok Deep Ensemble, uprkos solidnoj MACE kalibraciji prije CP-a, ovdje najviše podbacuje u odnosu na nominalni cilj ($0.922 < 0.95$), što ukazuje da rang metoda po kalibraciji nije stabilan između različitih metrika i konteksta evaluacije.

Vrijedi istaknuti i nalaz analize stabilnosti na temelju deset nezavisnih pokretanja modela, koji ukazuje na veću stabilnost predikcija kod Deep Ensemble pristupa. Deep Ensemble postiže najnižu standardnu devijaciju RMSE-a među sve tri UQ metode ($\text{std} = 0.11$), dok MC Dropout ($\text{std} = 0.18$) i hibridni BNN ($\text{std} = 0.23$) pokazuju nešto veću varijabilnost rezultata između pojedinačnih pokretanja. Deterministički baseline model pokazuje najveću standardnu devijaciju RMSE-a od svih modela ($\text{std} = 0.28$), što ukazuje na nešto veću varijabilnost rezultata između nezavisnih pokretanja u odnosu na UQ metode.

Gledajući sve rezultate zajedno, potvrđuje se centralna hipoteza rada: UQ metode postižu tačnost statistički usporedivu s determinističkim pristupom, budući da bootstrap analiza potvrđuje da razlike u RMSE-u između sva četiri modela nisu statistički značajne, uz dodatnu vrijednost kvantificirane nesigurnosti. Umjesto kompromisa na račun tačnosti, rezultati pokazuju da su tačnost i kalibracija nezavisne dimenzije kvaliteta modela: metode se međusobno ne razlikuju značajno po tačnosti, ali se jasno razlikuju po kvaliteti kalibracije nesigurnosti. Nijedna metoda ne dominira po svim metrikama istovremeno: Deep Ensemble postiže najnižu varijabilnost tačnosti, MC Dropout najuže intervale i najjednostavniju implementaciju, a hibridni BNN najbolju pokrivenost, uz MACE praktično izjednačen s Deep Ensemble-om. Za razliku od Deep Ensemble-a, i MC Dropout i hibridni BNN dodatno omogućavaju eksplicitnu dekompoziciju nesigurnosti na aleatoričku i epistemičku komponentu. Ovo je konzistentno s nalazima Basore et al. [8], koji na širem skupu metoda i skupa podataka zaključuju da ne postoji univerzalno superiorna UQ metoda za prognostiku, već da odabir ovisi o prioritetima konkretne primjene.

7. Zaključak

Centralno pitanje ovog rada bilo je može li se okvir za predikciju preostalog životnog vijeka industrijskih komponenti proširiti tako da uz tačkastu predikciju pruža i mjeru pouzdanosti, bez gubitka prediktivne preciznosti. Eksperimentalni rezultati na CMAPSS FD001 setu podataka daju jasan odgovor: sve tri implementirane metode kvantifikacije nesigurnosti postižu usporedivu tačnost determinističkom modelu, pri čemu *bootstrap* analiza potvrđuje da razlike između sva četiri modela nisu statistički značajne. Uvođenje probabilističkog tretmana ne uvodi kompromis u preciznosti, što demantira uobičajenu pretpostavku da je nesigurnost informacija koja se plaća smanjenjem tačnosti.

Istovremeno, rezultati rasvijetljavaju važnu distinkciju između tačnosti predikcije i kalibracije nesigurnosti kao dvije nezavisne dimenzije kvaliteta probabilističkog modela. Nijedna od triju metoda ne dostiže nominalni 95% nivo pokrivenosti bez naknadne kalibracije, pri čemu se metode razlikuju kako po stepenu, tako i po smjeru odstupanja od idealne kalibracije, što je detaljno razotkriveno dijagramom pouzdanosti. Konformna predikcija uspješno približava pokrivenost nominalnom cilju za sve tri metode, no za razliku od pokrivenosti, širina kalibriranih intervala ne konvergira ka zajedničkoj vrijednosti: metoda s manje konzervativnom originalnom procjenom nesigurnosti zadržava uže, informativnije intervale i nakon kalibracije, čime izbor metode ostaje relevantan i kada je pitanje garantovane pokrivenosti riješeno.

Analiza stabilnosti kroz deset nezavisnih pokretanja pokazuje da su sva četiri modela relativno konzistentna u tačnosti, sa standardnim devijacijama RMSE-a u rasponu od 0.11 (Deep Ensemble) do 0.28 ciklusa (Baseline LSTM). Deep Ensemble bilježi najnižu varijabilnost tačnosti od sve tri UQ metode, u skladu s teorijskim očekivanjem da agregacija nezavisno treniranih modela smanjuje varijansu predikcije. Razlika u standardnoj devijaciji između determinističkog baselinea i preostalih modela je pritom umjerena, posebno u odnosu na Hibridni BNN, te je stoga ne treba tumačiti kao dokaz da UQ metode same po sebi donose suštinski stabilniji proces treninga.

Po dimenziji kalibracije, Hibridni BNN ostvaruje najvišu pokrivenost prediktivnih intervala (0.85 naspram 0.82 kod Deep Ensemble-a i 0.80 kod MC Dropouta), što predstavlja jasnu i konzistentnu prednost ove metode. Po NLL-u (4.19 ± 0.29 naspram 4.16 ± 0.14 kod Deep Ensemble-a) i MACE-u (0.09 ± 0.03 naspram 0.09 ± 0.02), razlika između Hibridnog BNN-a i Deep Ensemble-a je zanemarljiva i u potpunosti unutar jedne standardne devijacije, pa se prednost po ove dvije metrike ne može smatrati statistički utvrđenom, obje metode su ovdje praktički izjednačene, dok je MC Dropout jasno najlošije kalibrirana metoda po svim trima kalibracijskim metrikama. Hibridni BNN, zajedno s MC Dropout metodom, dodatno omogućava aproksimativnu dekompoziciju ukupne nesigurnosti na epistemičku i aleatoričku komponentu, prednost koju Deep Ensemble, zbog hijerarhijske prirode svoje varijanse, ne nudi.

Nijedna metoda stoga ne dominira po svim razmatranim dimenzijama istovremeno: Deep Ensemble nudi najstabilniju tačnost i najuže kalibrirane intervale, Hibridni BNN postiže najvišu pokrivenost, dok po preciznosti kalibracije (NLL, MACE) ova dva modela ostaju statistički izjednačeni. MC Dropout i Hibridni BNN, za razliku od Deep Ensemble-a, dodatno omogućavaju

aproksimativnu dekompoziciju nesigurnosti na epistemičku i aleatoričku komponentu, dok MC Dropout, unatoč najslabijoj kalibraciji, ostaje računski najjednostavniji pristup bez potrebe za izmjenom arhitekture ili treninga. Odabir metode za konkretnu industrijsku primjenu stoga ovisi o tome koja se od ovih dimenzija: stabilnost tačnosti, preciznost kalibracije, mogućnost dekompozicije nesigurnosti ili računski cijena, smatra prioritetnom.

7.1 Prijedlozi za budući rad

Nekoliko pravaca istraživanja prirodno se nadovezuje na rezultate i ograničenja ovog rada. Najneposredniji doprinos bila bi primjena implementiranog okvira na složenije podskupove CMAPSS seta podataka koji modeliraju višestruke operativne uvjete i modove kvara [3]. Evaluacija na jednom operativnom uvjetu osigurava metodološku čistoću, ali ograničava generalizabilnost zaključaka. Posebno je zanimljivo ispitati ponašanje epistemičke nesigurnosti hibridnog BNN modela u scenariju distribucijske neusklađenosti: model treniran na FD001 podatkovnom skupu, primijenjen na FD002 koji modelira šest operativnih uvjeta, teorijski bi trebao pokazati porast epistemičke nesigurnosti jer nailazi na uvjete degradacije koje nije vidio tokom treninga [13]. Ovakav eksperiment direktno bi testirao praktičnu vrijednost dekompozicije nesigurnosti za detekciju primjera izvan distribucije u industrijskim sistemima.

Heuristička metoda dekompozicije korištena u ovom radu, zasnovana na percentilnoj aproksimaciji unutar RUL binova, predstavlja praktičan ali aproksimativan pristup. Prirodan nastavak bila bi implementacija arhitekture s dvije zasebne izlazne glave koje direktno uče heteroscedastičnu aleatoričku varijansu [6], čime bi se dobila precizna, a ne samo heuristička dekompozicija ukupne nesigurnosti za MC Dropout i hibridni BNN. Ovakvo proširenje bilo bi posebno vrijedno u kombinaciji s prethodno opisanim eksperimentom distribucijske neusklađenosti, jer bi omogućilo precizniju provjeru hipoteze da epistemička komponenta raste na OOD podacima, bez konfundirajućeg efekta heurističke aproksimacije.

Implementacija potpuno varijacionih rekurentnih slojeva predstavlja teorijski rigorozniji nastavak hibridnog pristupa korištenog u ovom radu. Trenutna arhitektura primjenjuje varijacionu inferenciju isključivo na gustim izlaznim slojevima, čime epistemička nesigurnost koja potječe iz modeliranja sekvencijalnih obrazaca degradacije nije u potpunosti obuhvaćena [14]. Zanimljivo je da je hibridni BNN u ovom radu, unatoč tome što varijacionu inferenciju primjenjuje isključivo na izlaznim gustim slojevima, ipak ostvario najvišu pokrivenost prediktivnih intervala od sve tri implementirane metode, uz MACE statistički izjednačen s Deep Ensembleom i jasno bolji od MC Dropouta; sistemsko ispitivanje doprinosi li potpuno varijacioni tretman rekurentnih slojeva daljem poboljšanju kalibracije, ili uvodi nestabilnost neproporcionalnu dobitku, predstavlja otvoreno pitanje. Benker et al. [21] demonstriraju da Hamiltonov Monte Carlo može pružiti kvalitetniju aproksimaciju posteriorne distribucije na CMAPSS setu podataka u poređenju s varijacionom inferencijom, što predstavlja pravac vrijedan istraživanja, posebno u kombinaciji s hibridnom arhitekturom koja zadržava deterministički enkoder radi računski efikasnosti.

Sistemsko istraživanje odnosa između broja članova Deep Ensemble ansambla, stabilnosti rezultata i računski cijene ostaje relevantan pravac budućeg rada. Iako je ansambl od pet članova u ovom radu pokazao najnižu varijansu tačnosti od svih implementiranih UQ metoda, otvoreno pitanje ostaje u kojoj mjeri se ta stabilnost i kvalitet kalibracije dalje mijenjaju s većim brojem članova, te kakav je odnos graničnog poboljšanja i dodatnog računskog troška u primjenama s ograničenim resursima.

Konačno, konformna kalibracija implementirana u ovom radu demonstrirala je svoju efikasnost kao *post-hoc* tehnika za približavanje pokrivenosti prediktivnih intervala nominalnom

cilju, uz zapažanje da širina kalibriranih intervala ostaje različita među metodama i nakon kalibracije. Prirodno proširenje bilo bi integracija *adaptive conformal prediction* metoda koje, za razliku od standardnog pristupa korištenog u ovom radu, konstruiraju intervale različite širine ovisno o lokalnoj nesigurnosti modela, čime se postiže bolja oštrina uz zadržavanje teorijske garancije pokrivenosti [27]. Ovakav pristup bio bi posebno koristan u kontekstu RUL predikcije gdje nesigurnost nije uniformna kroz cijeli raspon degradacije, a mogao bi dodatno smanjiti razlike u širini intervala primijećene između metoda u ovom radu.

Literatura

- [1] Lee, J., Wu, F., Zhao, W., Ghaffari, M., Liao, L., Siegel, D., “Prognostics and Health Management Design for Rotary Machinery Systems—Reviews, Methodology and Applications”, *Mechanical Systems and Signal Processing*, Vol. 42, No. 1, 2014, str. 314–334.
- [2] Zheng, S., Ristovski, K., Farahat, A., Gupta, C., “Long Short-Term Memory Network for Remaining Useful Life Estimation”, in *2017 IEEE International Conference on Prognostics and Health Management (ICPHM)*. IEEE, 2017, str. 88–95.
- [3] Saxena, A., Goebel, K., Simon, D., Eklund, N., “Damage Propagation Modeling for Aircraft Engine Run-to-Failure Simulation”, in *2008 International Conference on Prognostics and Health Management*. IEEE, 2008, str. 1–9.
- [4] Gneiting, T., Raftery, A. E., “Strictly Proper Scoring Rules, Prediction, and Estimation”, *Journal of the American Statistical Association*, Vol. 102, No. 477, 2007, str. 359–378.
- [5] Kiureghian, A. D., Ditlevsen, O., “Aleatory or Epistemic? Does it Matter?”, *Structural Safety*, Vol. 31, No. 2, 2009, str. 105–112.
- [6] Kendall, A., Gal, Y., “What Uncertainties Do We Need in Bayesian Deep Learning for Computer Vision?”, *Advances in Neural Information Processing Systems*, Vol. 30, 2017.
- [7] Hüllermeier, E., Waegeman, W., “Aleatoric and Epistemic Uncertainty in Machine Learning: An Introduction to Concepts and Methods”, *Machine Learning*, Vol. 110, 2021, str. 457–506.
- [8] Basora, L., Viens, A., Chao, M. A., Olive, X., “A Benchmark on Uncertainty Quantification for Deep Learning Prognostics”, *arXiv preprint arXiv:2302.04730*, 2023.
- [9] Gal, Y., Ghahramani, Z., “Dropout as a Bayesian approximation: Representing model uncertainty in deep learning”, in *Proceedings of the 33rd International Conference on Machine Learning (ICML)*, Vol. 48, 2016, str. 1050–1059.
- [10] Lakshminarayanan, B., Pritzel, A., Blundell, C., “Simple and scalable predictive uncertainty estimation using deep ensembles”, in *Advances in Neural Information Processing Systems (NeurIPS)*, Vol. 30, 2017.
- [11] Blundell, C., Cornebise, J., Kavukcuoglu, K., Wierstra, D., “Weight uncertainty in neural networks”, in *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, 2015, str. 1613–1622.
- [12] Zhang, J., Wang, P., Yan, R., Gao, R. X., “Long Short-Term Memory for Machine Remaining Life Prediction”, *Journal of Manufacturing Systems*, Vol. 48, 2018, str. 78–86.
- [13] Srinivasan, A., Andresen, J. C., Holst, A., “Ensemble Neural Networks for Remaining Useful Life (RUL) Prediction”, *arXiv preprint arXiv:2309.12445*, 2023.

- [14] Jospin, L. V., Laga, H., Boussaid, F., Buntine, W., Bennamoun, M., “Hands-on Bayesian neural networks—a tutorial for deep learning users”, *IEEE Computational Intelligence Magazine*, Vol. 17, No. 2, 2022, str. 29–48.
- [15] Hochreiter, S., Schmidhuber, J., “Long Short-Term Memory”, *Neural Computation*, Vol. 9, No. 8, 1997, str. 1735–1780.
- [16] MacKay, D. J. C., “A practical Bayesian framework for backpropagation networks”, *Neural Computation*, Vol. 4, No. 3, 1992, str. 448–472.
- [17] Graves, A., “Practical variational inference for neural networks”, in *Advances in Neural Information Processing Systems (NeurIPS)*, Vol. 24, 2011.
- [18] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., Salakhutdinov, R., “Dropout: A simple way to prevent neural networks from overfitting”, *Journal of Machine Learning Research*, Vol. 15, No. 1, 2014, str. 1929–1958.
- [19] Dietterich, T. G., “Ensemble methods in machine learning”, in *Multiple Classifier Systems*, ser. *Lecture Notes in Computer Science*. Springer, 2000, Vol. 1857, str. 1–15.
- [20] Caceres, J., Gonzalez, D., Zhou, T., Droguett, E. L., “A probabilistic Bayesian recurrent neural network for remaining useful life prognostics considering epistemic and aleatory uncertainties”, *Structural Control and Health Monitoring*, Vol. 28, No. 10, 2021, str. e2811.
- [21] Benker, M., Furtner, L., Semm, T., Zaeh, M. F., “Utilizing uncertainty information in remaining useful life estimation via Bayesian neural networks and Hamiltonian Monte Carlo”, *Journal of Manufacturing Systems*, Vol. 61, 2021, str. 799–807.
- [22] Kuleshov, V., Fenner, N., Ermon, S., “Accurate Uncertainties for Deep Learning Using Calibrated Regression”, in *Proceedings of the 35th International Conference on Machine Learning*, 2018, str. 2796–2804.
- [23] Chung, Y., Char, I., Guo, H., Schneider, J., Neiswanger, W., “Beyond Pinball Loss: Quantile Methods for Calibrated Uncertainty Quantification”, in *Advances in Neural Information Processing Systems*, Vol. 34, 2021, str. 10 971–10 984.
- [24] Kingma, D. P., Welling, M., “Auto-encoding variational Bayes”, *arXiv preprint arXiv:1312.6114*, 2013.
- [25] Benesty, J., Chen, J., Huang, Y., Cohen, I., “Pearson correlation coefficient”, in *Noise Reduction in Speech Processing*, ser. *Springer Topics in Signal Processing*. Springer, 2009, Vol. 2, str. 1–4.
- [26] Guyon, I., Elisseeff, A., “An introduction to variable and feature selection”, *Journal of Machine Learning Research*, Vol. 3, 2003, str. 1157–1182.
- [27] Angelopoulos, A. N., Bates, S., “A gentle introduction to conformal prediction and distribution-free uncertainty quantification”, *arXiv preprint arXiv:2107.07511*, 2021.
- [28] Vovk, V., Gammerman, A., Shafer, G., *Algorithmic Learning in a Random World*. Springer, 2005.
- [29] Efron, B., “Bootstrap Methods: Another Look at the Jackknife”, *The Annals of Statistics*, Vol. 7, No. 1, 1979, str. 1–26.

Prilog A: Izvorni kod implementacije

Ovaj prilog sadrži ključne dijelove izvornog koda korištenog za implementaciju i evaluaciju metoda opisanih u radu. Isječci su grupisani prema poglavljima na koja se odnose, uz kratke komentare koji objašnjavaju njihovu svrhu i mjesto u ukupnom postupku.

Kompletni izvorni kod, uključujući implementaciju svih modela, provedene eksperimente, rezultate i pripadajuće materijale, dostupan je na GitHub repozitoriju:

<https://github.com/mdzafic/uq-predictive-maintenance-framework>

A.1 Podjela na trening i validacioni skup po motorima

Podjela se vrši prema identifikatoru motora, čime se osigurava da sekvence istog motora ne budu istovremeno prisutne u oba skupa i sprječava curenje informacija.

```
1 train_ids, val_ids = train_test_split(  
2     train['engine_id'].unique(), test_size=0.2, random_state=42)  
3  
4 train_subset = train[train['engine_id'].isin(train_ids)]  
5 val_subset   = train[train['engine_id'].isin(val_ids)]  
6  
7 X_tr, y_tr   = create_sequences(train_subset, feature_columns, seq_length)  
8 X_val, y_val = create_sequences(val_subset, feature_columns, seq_length)
```

Program 7.1: Podjela skupa po engine_id i formiranje sekvenci

A.2 Konstrukcija RUL labela i vremenskih sekvenci

Nakon primjene *piecewise* linear ograničenja opisanog u Sekciji 5.4, formiraju se sekvence dužine 40 ciklusa pristupom kliznog prozora. Za svaki prozor, kao ulazna sekvenca uzimaju se vrijednosti obilježja unutar tog raspona, dok se kao izlazna labela koristi RUL vrijednost ciklusa koji neposredno slijedi nakon prozora.

```
1 train['RUL'] = train.groupby('engine_id')['cycle'].transform('max') - train['cycle']  
2 train['RUL'] = train['RUL'].clip(upper=125)  
3 seq_length = 40  
4  
5 def create_sequences(data, seq_length, feature_columns):  
6     xs, ys = [], []  
7     for engine_id in data['engine_id'].unique():  
8         engine_data = data[data['engine_id'] == engine_id]  
9         for i in range(len(engine_data) - seq_length):  
10            x = engine_data.iloc[i:i + seq_length][feature_columns].values  
11            y = engine_data.iloc[i + seq_length]['RUL']  
12            xs.append(x)  
13            ys.append(y)  
14     return np.array(xs), np.array(ys)
```

Program 7.2: RUL labela i klizni prozor dužine W

A.3 Zajednička LSTM arhitektura

```

1 def build_lstm_model(seq_length, n_features, dropout_rate=0.3):
2     model = tf.keras.Sequential([
3         tf.keras.layers.Input(shape=(seq_length, n_features)),
4         tf.keras.layers.LSTM(64, return_sequences=True),
5         tf.keras.layers.Dropout(dropout_rate),
6         tf.keras.layers.LSTM(32),
7         tf.keras.layers.Dropout(dropout_rate),
8         tf.keras.layers.Dense(32, activation='relu'),
9         tf.keras.layers.Dense(1)])
10    model.compile(optimizer='adam', loss='mse', metrics=['mae'])
11    return model

```

Program 7.3: Zajednička LSTM arhitektura korištena za sva četiri modela

A.4 Monte Carlo Dropout: stohastička inferencija

Dropout slojevi ostaju aktivni tokom inferencije (`training=True`), čime se za svaki ulaz dobiva $T = 100$ stohastičkih uzoraka predikcije.

```

1 def mc_dropout_predict(model, X, T=100):
2     preds = np.stack([model(X, training=True).numpy().flatten()
3                       for _ in range(T)], axis=0)
4     return preds.mean(axis=0), preds.std(axis=0)
5
6 mc_mean, mc_std = mc_dropout_predict(mc_model, X_test, T=100)

```

Program 7.4: MC Dropout inferencija sa T stohastičkih prolaza

A.5 Deep Ensemble: nezavisno treniranje i agregacija

```

1 K, M = 5, 20 # broj članova ansambla, stohastičkih prolaza po članu
2 ensemble_all_samples = []
3
4 for k in range(K):
5     tf.random.set_seed(BASE_SEED_FINAL + k)
6     member = build_lstm_model(seq_length, n_features, dropout_rate=0.3)
7     member.fit(X_tr, y_tr, epochs=50, batch_size=64, verbose=0)
8     member_preds = np.stack([member(X_test, training=True).numpy().flatten()
9                              for _ in range(M)], axis=0)
10    ensemble_all_samples.append(member_preds)
11
12 all_samples = np.vstack(ensemble_all_samples)
13 ens_mean, ens_std = all_samples.mean(axis=0), all_samples.std(axis=0)

```

Program 7.5: Treniranje K nezavisnih članova ansambla i agregacija predikcija

A.6 Hibridna BNN: DenseVariational sloj

Rekurentni dio mreže je deterministički, dok se varijaciona inferencija primjenjuje samo na izlaznim gustim slojevima pomoću reparametrizacijskog trika.

```

1 class DenseVariational(tf.keras.layers.Layer):
2     def __init__(self, units, activation=None, kl_weight=1.0, **kw):
3         super().__init__(**kw)
4         self.units, self.kl_weight = units, kl_weight
5         self.activation = tf.keras.activations.get(activation)

```

```

6     def build(self, input_shape):
7         n_in = int(input_shape[-1])
8         init_rho = tf.initializers.constant(-3.0)
9         self.kernel_mu = self.add_weight((n_in, self.units), initializer='glorot_normal')
10        self.kernel_rho = self.add_weight((n_in, self.units), initializer=init_rho)
11        self.bias_mu = self.add_weight((self.units,), initializer='zeros')
12        self.bias_rho = self.add_weight((self.units,), initializer=init_rho)
13
14    def call(self, inputs, training=None):
15        k_sig = tf.nn.softplus(self.kernel_rho) + 1e-5
16        b_sig = tf.nn.softplus(self.bias_rho) + 1e-5
17        if training:
18            kernel = self.kernel_mu + k_sig * tf.random.normal(self.kernel_mu.shape)
19            bias = self.bias_mu + b_sig * tf.random.normal(self.bias_mu.shape)
20        else:
21            kernel, bias = self.kernel_mu, self.bias_mu
22
23        kl = self._kl(self.kernel_mu, k_sig) + self._kl(self.bias_mu, b_sig)
24        self.add_loss(self.kl_weight * kl / n_train)
25        out = tf.matmul(inputs, kernel) + bias
26        return self.activation(out) if self.activation else out
27
28    def _kl(self, mu, sigma):
29        return 0.5 * tf.reduce_sum(tf.square(mu) + tf.square(sigma)
30                                   - tf.math.log(tf.square(sigma)) - 1.0)

```

Program 7.6: Bayesovski gusti sloj sa reparametrizacijskim trikom

A.7 Metrike kvantifikacije nesigurnosti

Za prediktivne intervale računaju se pokrivenost, prosječna širina intervala i negativna log-vjerovatnoća; kalibracija se dodatno procjenjuje srednjom apsolutnom kalibracionom greškom.

```

1  def evaluate_uncertainty(y_true, y_mean, y_std, confidence=0.95):
2      z = norm.ppf(1 - (1 - confidence) / 2)
3      lower, upper = y_mean - z * y_std, y_mean + z * y_std
4      coverage = np.mean((y_true >= lower) & (y_true <= upper))
5      miw = np.mean(upper - lower)
6      nll = -np.mean(norm.logpdf(y_true, loc=y_mean, scale=y_std))
7      return coverage, miw, nll
8
9  def calibration_curve_uq(y_true, y_mean, y_std, n_levels=20):
10     alphas, observed = np.linspace(0.05, 0.99, n_levels), []
11     for a in alphas:
12         z = norm.ppf(1 - (1 - a) / 2)
13         lower, upper = y_mean - z * y_std, y_mean + z * y_std
14         observed.append(np.mean((y_true >= lower) & (y_true <= upper)))
15     return alphas, np.array(observed)
16
17 def mean_absolute_calibration_error(nominal, observed):
18     return np.mean(np.abs(nominal - observed))

```

Program 7.7: Pokrivenost, MIW, NLL i kalibraciona kriva

Pored evaluacije kvaliteta prediktivnih intervala, provedena je i aproksimativna dekompozicija ukupne nesigurnosti na aleatoričku i epistemičku komponentu:

```

1  def estimate_aleatoric(y_true, y_std, n_bins=10):
2      bins = np.linspace(y_true.min(), y_true.max(), n_bins + 1)
3      aleatoric = np.zeros_like(y_std)
4      for i in range(n_bins):
5          mask = (y_true >= bins[i]) & (y_true < bins[i + 1])
6          if mask.sum() > 0:
7              aleatoric[mask] = np.percentile(y_std[mask], 10)
8      epistemic = np.maximum(y_std - aleatoric, 0)
9      return aleatoric, epistemic

```

Program 7.8: Aproksimativna dekompozicija na aleatoričku i epistemičku nesigurnost

A.8 Analiza osjetljivosti hiperparametara

Odabir hiperparametara (W , p , broj epoha) zasniva se na one-at-a-time (OFAT) analizi na validacionom skupu, uz tri nezavisna sjemena po vrijednosti. Prikazan je primjer za dropout stopu p ; isti obrazac korišten je i za dužinu prozora W , broj epoha treninga i dropout stopu u hibridnom BNN modelu.

```

1 SEEDS, P_VALUES = [42, 123, 7], [0.1, 0.2, 0.3, 0.4, 0.5]
2
3 def evaluate_mc_dropout(model, X, y, n_samples=50, z=1.96):
4     preds = np.array([model(X, training=True).numpy().flatten()
5                       for _ in range(n_samples)])
6     mean_p, std_p = preds.mean(axis=0), preds.std(axis=0)
7     lower, upper = mean_p - z * std_p, mean_p + z * std_p
8     rmse = np.sqrt(mean_squared_error(y, mean_p))
9     coverage = np.mean((y >= lower) & (y <= upper))
10    return rmse, coverage, np.mean(upper - lower)
11
12 results_p = []
13 for p in P_VALUES:
14     rmse_r, cov_r, width_r = [], [], []
15     for seed in SEEDS:
16         random.seed(seed); np.random.seed(seed); tf.random.set_seed(seed)
17         m = build_lstm_model(seq_length, len(feature_columns), dropout_rate=p)
18         m.fit(X_tr, y_tr, epochs=50, batch_size=64,
19             validation_data=(X_val, y_val),
20             callbacks=[EarlyStopping(monitor='val_loss', patience=10,
21                                     restore_best_weights=True)], verbose=0)
22         r, c, w = evaluate_mc_dropout(m, X_val, y_val)
23         rmse_r.append(r); cov_r.append(c); width_r.append(w)
24     results_p.append({'p': p, 'val_RMSE_mean': np.mean(rmse_r),
25                     'val_Coverage_mean': np.mean(cov_r),
26                     'mean_interval_width': np.mean(width_r)})

```

Program 7.9: OFAT analiza osjetljivosti na dropout stopu p

A.9 Conformal Prediction kalibracija

Za *post-hoc* kalibraciju testni skup se dijeli na kalibracijski i evaluacijski dio. Na kalibracijskom dijelu računaju se apsolutne greške predikcije, iz kojih se određuje konformni kvantil $\hat{q}$; konačni interval formira se dodavanjem/oduzimanjem ovog kvantila od predikcije.

```

1 np.random.seed(42)
2 n_cal = int(0.2 * len(y_test))
3 cal_idx = np.random.choice(len(y_test), size=n_cal, replace=False)
4 test_idx = np.array([i for i in range(len(y_test)) if i not in cal_idx])
5
6 y_cal, y_test_cp = y_test[cal_idx], y_test[test_idx]
7 alpha_target = 0.05
8
9 cal_scores = np.abs(y_cal - mc_mean[cal_idx])
10 q_hat = np.quantile(cal_scores, (1 - alpha_target) * (1 + 1 / n_cal))
11
12 cp_lower = mc_mean[test_idx] - q_hat
13 cp_upper = mc_mean[test_idx] + q_hat
14 cp_coverage = np.mean((y_test_cp >= cp_lower) & (y_test_cp <= cp_upper))

```

Program 7.10: Split conformal kalibracija prediktivnih intervala